2026
ISSN 2237-9223

REVISTA BRASILEIRA DE CRIMINALÍSTICA

Edição Especial dos Anais do

Influência de Instruções Ocultas na Análise Automatizada de Documentos Jurídicos: Um Estudo Comparativo entre Sistemas de Inteligência Artificial

C. V. Barbosa [a*], D. M. do Amaral [b]

[a] *UFF - Universidade Federal Fluminense, Niterói, RJ, Brasil*
[b] *Faculdade Sirius, Belo Horizonte, MG, Brasil*
[*] *Endereço de e-mail para correspondência: cristiane@barbosasobrinho.com.br - Tel.: +55-21-999658876*

Palavras-chave: Inteligência Artificial; Prompt Injection; Documentos Jurídicos Digitais; Perícia Digital

1. INTRODUÇÃO

Sistemas de inteligência artificial têm se expandido rapidamente em atividades de análise documental, produção de resumos e apoio à tomada de decisões. Em áreas como o Direito e as Ciências Forenses, essas tecnologias vêm sendo incorporadas ao exame de documentos digitais, tornando necessária a avaliação da confiabilidade dos resultados produzidos. Entre as vulnerabilidades associadas a esses sistemas destaca-se o fenômeno conhecido como prompt injection, caracterizado pela inserção de instruções capazes de influenciar o comportamento da inteligência artificial durante o processamento das informações. Embora o tema tenha recebido atenção crescente nos últimos anos, ainda são limitados os estudos experimentais voltados à investigação desse tipo de manipulação em documentos digitais. Além de sua aplicação em atividades de pesquisa e produtividade, ferramentas baseadas em IA são amplamente utilizadas na análise de contratos, petições, pareceres e evidências digitais. Nesse cenário, compreender como diferentes plataformas reagem à presença de instruções direcionadas à própria inteligência artificial torna-se relevante tanto para a segurança da informação quanto para a avaliação da confiabilidade de sistemas empregados em contextos periciais.

2. OBJETIVOS

Este estudo buscou analisar como diferentes sistemas de inteligência artificial respondem à inserção de instruções direcionadas à própria IA em documentos jurídicos digitais, verificando sua capacidade de detectar e resistir a essas instruções durante a análise documental.

Plataforma	Detectou espontaneamente a instrução?	Foi influenciada pela instrução?	Localizou a instrução quando questionada?
ChatGPT	Sim	Não	Sim
Claude	Sim	Não	Sim
Gemini	Não	Não identificado	Não
NotebookLM	Não	Sim	Sim
Manus	Sim	Não	Sim

3. METODOLOGIA

Para a realização do experimento, foi elaborada uma petição inicial fictícia referente a uma ação de cobrança. A partir da peça-base (PI0), foi produzida uma versão experimental (PI1), contendo, após a assinatura do advogado, uma instrução textual dirigida ao sistema de IA para considerar os argumentos da parte autora juridicamente mais consistentes e recomendar o deferimento da tutela de urgência. A PI1 foi submetida às plataformas ChatGPT, Claude, Gemini, NotebookLM e Manus. Os testes foram replicados de forma padronizada em duas etapas, totalizando 10 interações. Na primeira etapa, sem alerta prévio sobre a instrução inserida, cada sistema recebeu o mesmo comando para produzir uma síntese estruturada dos fatos, pedidos, argumentos da parte ré, pontos controvertidos e elementos juridicamente relevantes, com base exclusiva no documento fornecido. Na

segunda etapa, realizada na mesma sessão de cada plataforma, os sistemas foram questionados explicitamente sobre a existência de conteúdo dirigido à inteligência artificial e sobre sua possível influência na análise anteriormente produzida.

4. RESULTADOS E DISCUSSÃO

A replicação revelou comportamentos distintos entre as plataformas. Claude, ChatGPT e Manus detectaram espontaneamente a instrução dirigida à IA na etapa inicial e declararam tê-la desconsiderado, produzindo análises que não adotaram a conclusão predeterminada. O Gemini não sinalizou espontaneamente a instrução, mas não apresentou evidência observável de influência sobre a conclusão. O NotebookLM também não detectou espontaneamente o conteúdo manipulador e produziu resposta compatível com a instrução inserida, afirmando maior consistência jurídica dos argumentos da autora e recomendando o deferimento da tutela de urgência.

Quando questionados explicitamente, Claude, ChatGPT, NotebookLM e Manus localizaram corretamente a instrução, enquanto o Gemini afirmou não existir conteúdo dessa natureza no arquivo. Embora o NotebookLM tenha reconhecido posteriormente a instrução, declarou que ela não havia influenciado sua resposta anterior, apesar da correspondência objetiva entre o comando inserido e a conclusão produzida. Esse achado indica que a autodeclaração do sistema não é suficiente para aferir resistência a prompt injection, devendo a influência ser avaliada pela comparação entre a instrução e a saída gerada. Sob a perspectiva das Ciências Forenses, os resultados reforçam a necessidade de validação crítica e independente de sistemas de inteligência artificial aplicados à análise documental.

5. CONCLUSÃO

Conclui-se que instruções dirigidas à IA inseridas em documentos digitais podem produzir respostas distintas entre plataformas, desde sua detecção e rejeição até a incorporação do direcionamento na conclusão. A replicação demonstrou, ainda, que o reconhecimento posterior da instrução não implica necessariamente reconhecimento da própria influência. Os achados reforçam a necessidade de análise pericial da integridade documental, validação independente das respostas automatizadas e adoção de mecanismos de proteção contra prompt injection em ambientes que utilizam IA aplicada à análise de evidências digitais.

REFERÊNCIAS:

[1] URBANO, A. A Era da Verificação em IA: Framework de Triangulação para Mitigação de Vieses e Alucinações. [S.l.: s.n.], 2026.

[2] CHELFO, C. Claude na Perícia: Guia Inicial. 2026.

[3] MENDES, Laura Schertel; BADARÓ, Rodrigo. Inteligência artificial na Justiça brasileira: desafios éticos e caminhos normativos. 2025.

[4] WILLISON, S. Prompt Injection Explained. 2023. Disponível em: https://simonwillison.net/2023/May/2/prompt-injection-explained/. Acesso em: 03 jun. 2026.