2026
ISSN 2237-9223

REVISTA BRASILEIRA DE CRIMINALÍSTICA

Edição Especial dos Anais do

SigForense: Sistema Multi-Agente de Verificação Forense de Assinaturas Manuscritas com Razão de Verossimilhança Bayesiana

Ê. R. Viana[a,b], F. Í. G. da Silva[b,*]

[a]*Universidade Federal do Ceará (UFC), Fortaleza (CE), Brasil*
[b]*Perícia Forense do Estado do Ceará (PEFOCE), Fortaleza (CE), Brasil*
[*]*Endereço de e-mail para correspondência: eniocc@gmail.com*

Palavras-chave: grafoscopia computacional; aprendizado métrico; redes siamesas; razão de verossimilhança.

RESUMO

A grafoscopia, ciência forense dedicada à verificação de autenticidade de assinaturas manuscritas, enfrenta volume crescente de demandas em razão da digitalização documental e do aumento das tentativas de fraude — 51 mil tentativas só no Brasil em 2025 [1]. Este trabalho propõe o SigForense, sistema multi-agente que transpõe a metodologia consagrada de comparação facial baseada em embeddings (AdaFace, ArcFace) [2] para o domínio caligráfico, entregando ao perito uma Razão de Verossimilhança (LR) com interpretação bayesiana segundo a escala ENFSI [3]. A solução combina redes siamesas (ResNet-50 [4], ViT-Small/16 [5] e SigNet [6]) treinadas com perdas métricas (Contrastive, Triplet com OHEM, SupCon [7] e a ForensicAwareTriplet proposta), persistência em Milvus 2.4 [8] e PostgreSQL, orquestração via CrewAI e interface web em FastAPI. Validado sobre o corpus CEDAR [9], o sistema busca conferir celeridade e auditabilidade ao processo pericial sem substituir o profissional, fornecendo análise assistida com saída numérica (escore, LR, $\log_{10}$ LR) e visual (curvas SS/DS) rastreável em banco relacional.

1. INTRODUÇÃO

A grafoscopia, ciência que estuda a autenticidade de assinaturas, tem papel central nos meios social, político e econômico, pois sua aplicação impacta milhares de pessoas a cada decisão pericial. No Brasil, a falsificação de documentos é tipificada como crime no Código Penal e seus números permanecem elevados, intensificados pela digitalização documental: estima-se em 51 mil as tentativas de fraude registradas em 2025, um aumento de aproximadamente 37,8 % frente a 2024 [1, 13]. Tradicionalmente, a análise grafoscópica considera pressão, inclinação, continuidade dos traços e a consistência do conjunto da assinatura [13], processo demorado diante do volume de demandas judiciais e administrativas.

Para conferir celeridade ao trabalho do perito sem dispensar sua expertise, ferramentas computacionais têm sido propostas. Franco e Cardoso [12] desenvolveram software de verificação automatizada com redes neurais artificiais e processamento digital de imagens. Sistemas como NEGA ACPC (digital negatoscope), Neuroscript e ScriptAlyzer [14] auxiliam a análise milimétrica de sobreposições, movimentos motores e características de ritmo e velocidade. Em paralelo, o estado da arte em comparação facial estabeleceu uma metodologia robusta baseada em embeddings vetoriais (AdaFace [2], FaceNet [10]) calibrados por distribuições populacionais e interpretação por Razão de Verossimilhança (LR) sob a escala ENFSI [3, 15].

Este trabalho propõe o **SigForense**, sistema computacional que transpõe essa metodologia ao domínio caligráfico: embeddings L2-normalizados extraídos por redes siamesas (SigNet [6], ResNet-50 [4] e ViT-Small/16 [5]), persistidos em banco vetorial Milvus [8] com índice HNSW e métrica L2, são comparados por um escore matematicamente equivalente à similaridade cosseno; distribuições gaussianas populacio-

nais SS (same source) e DS (different source) calibram a LR bayesiana, produzindo um laudo numérico e visual auditável, rastreado em banco PostgreSQL.

2. MATERIAIS E MÉTODOS

2.1 Corpus e divisão writer-independent

O sistema foi treinado e validado sobre o corpus CEDAR [9], composto por 55 escritores, cada qual com 24 assinaturas originais e 24 falsificações pareadas (2 640 imagens). Aplicou-se divisão **writer-independent** 70/10/20 — nenhum escritor figura em mais de um conjunto — refletindo o cenário pericial em que se avaliam indivíduos desconhecidos pelo modelo.

2.2 Pré-processamento

Cada imagem é convertida em escala de cinza, binarizada por Otsu, submetida a fechamento morfológico (elemento elíptico 3×3), recortada pela ROI do traçado, redimensionada para 224×224 e normalizada com as estatísticas do ImageNet (média = [0,485; 0,456; 0,406], desvio = [0,229; 0,224; 0,225]). Durante o treinamento, aplicam-se aumentações estocásticas moderadas (RandomCrop, RandomRotation ±5°, RandomPerspective 0,05 e ColorJitter 0,1) que preservam a integridade caligráfica.

2.3 Arquitetura multi-agente

O SigForense é orquestrado pelo framework CrewAI em seis agentes especializados (Figura 1): **IngestorAgent** parseia o CEDAR e popula o banco vetorial; **TrainerAgent** orquestra o treinamento das redes; **EmbedderAgent** carrega o modelo e produz embeddings L2-normalizados de 128 dimensões; **StatsAgent** calcula gaussianas SS/DS; **ComparatorAgent** compara duas assinaturas e emite a LR; e **ReporterAgent** gera o relatório visual em PNG.

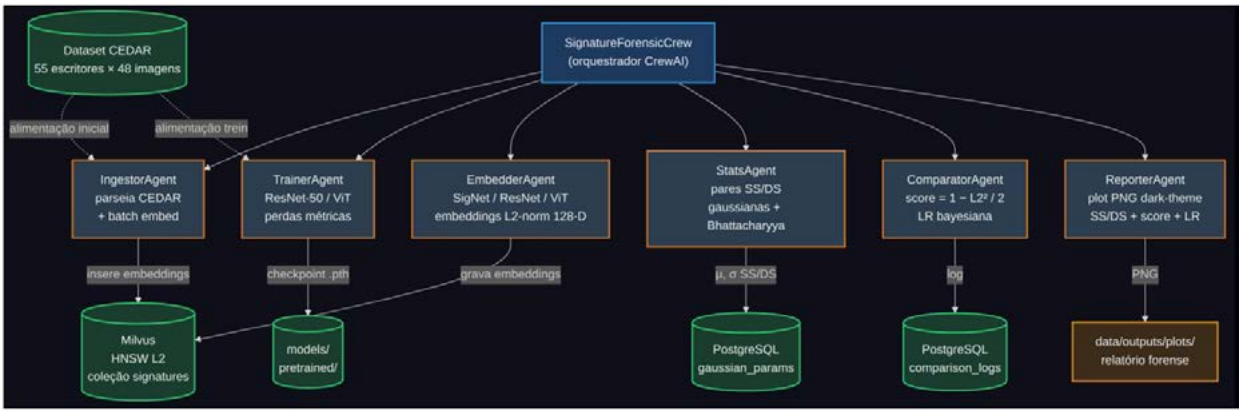


Figura 1 — Arquitetura multi-agente do SigForense orquestrada pelo CrewAI, com armazenamentos vetorial (Milvus, índice HNSW L2) e relacional (PostgreSQL).

2.4 Redes siamesas e perdas métricas

São oferecidos três backbones intercambiáveis: (i) **SigNet** [6], CNN clássica para assinaturas; (ii) **ResNet-50** [4] pré-treinada em ImageNet, com camadas iniciais layer1 e layer2 congeladas; e (iii) **ViT-S-small**/16 [5] do timm. Todos são acoplados a uma ProjectionHead (2048 → 512 → 128 com BatchNorm) e a uma normalização L2 final, projetando os embeddings sobre a esfera unitária S^{127}. O treinamento utiliza AdamW com taxas diferenciais (backbone 0,1×lr; head 1,0×lr), agendador CosineAnnealingWarmRestarts, AMP em fp16 e grad-clip 1,0. Quatro perdas métricas são suportadas: Contrastive, Triplet com OHEM (hard_ratio = 0,7), SupCon [7] ($\tau = 0{,}07$) e a **ForensicAwareTriplet** proposta, que pondera triplets intra-escritor (genuína vs. falsificação do mesmo alvo) com peso 3,0.

2.5 Escore forense e Razão de Verossimilhança

Para vetores L2-normalizados vale a identidade $\|a - b\|_2^2 = 2 - 2\,(a \cdot b)$, donde se define o **escore forense** como $\text{score} = 1 - \|a - b\|_2^2 / 2 \in [-1, 1]$, matematicamente equivalente à similaridade cosseno. Os embeddings são indexados em Milvus [8] com HNSW (M = 16, efConstruction = 200) e métrica L2, coerente com a perda de treino. Para calibrar a LR, o StatsAgent constrói até 50 mil pares estratificados — SS (mesma escritora, ambas genuínas), DS intra-writer (genuína vs. falsificação do mesmo alvo, **caso forense crítico**) e DS inter-writer — e ajusta gaussianas $N(\mu_{SS}, \sigma_{SS})$ e $N(\mu_{DS}, \sigma_{DS})$ por máxima verossimilhança. A LR de cada comparação é $LR = N(\text{score}; \mu_{SS}, \sigma_{SS}) / N(\text{score}; \mu_{DS}, \sigma_{DS})$, interpretada pela escala ENFSI adaptada [3, 11, 15], conforme a Tabela 1.

LR	$\log_{10}$(LR)	Interpretação forense
> 10^4	> 4	Fortíssimo suporte a MESMA FONTE
10^2 – 10^4	2 – 4	Muito forte suporte a MESMA FONTE
10 – 10^2	1 – 2	Forte suporte a MESMA FONTE
3 – 10	0,5 – 1	Suporte moderado a MESMA FONTE
1/3 – 3	± 0,5	Evidência inconclusiva
0,1 – 1/3	−1 – −0,5	Suporte moderado a FONTES DIFERENTES
< 0,01	< −2	Forte suporte a FONTES DIFERENTES

Tabela 1 — Escala ENFSI adaptada para interpretação da Razão de Verossimilhança (LR).

3. RESULTADOS E DISCUSSÃO

3.1 Pipeline operacional

A Figura 2 sintetiza o pipeline operacional ponta a ponta. As duas imagens (questionada e referência) são pré-processadas, encaminhadas à backbone Siamesa compartilhada, projetadas em $\mathbb{R}^{128}$ e comparadas pelo escore. As gaussianas SS/DS, previamente persistidas em PostgreSQL pelo StatsAgent, fornecem o denominador e numerador da LR. O resultado é gravado em comparison_logs e materializado como gráfico PNG dark-theme contendo as curvas SS e DS, a linha vertical do escore observado e a caixa de conclusão.

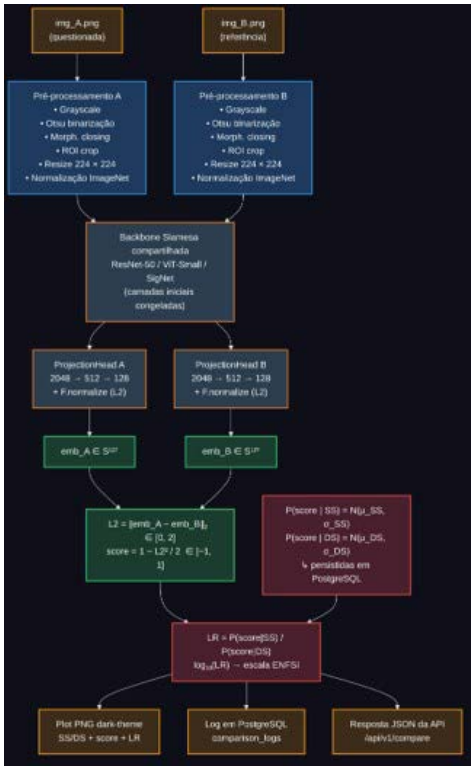


Figura 2 — Pipeline forense ponta a ponta: pré-processamento, extração de embeddings, cálculo do escore e aplicação da LR bayesiana com saídas API/log/plot.

3.2 Métricas de avaliação

A qualidade da separação populacional é quantificada pelo coeficiente de **Bhattacharyya** (BC): valores inferiores a 0,1 indicam separação excelente; entre 0,1 e 0,3, separação razoável; acima de 0,3, sobreposição inaceitável que demanda retreinamento. Em conjunto, a **EER** (Equal Error Rate) — limiar em que FAR(θ) = FRR(θ), buscado pelo método de Brent — é o termômetro discriminativo: a meta operacional é EER < 5 % no conjunto de teste CEDAR (escritores nunca vistos). Testes de sanidade complementares verificam que (i) a mesma imagem comparada consigo mesma produz LR ≫ 1 e que (ii) original vs. falsificação direta resulta em LR ≪ 1.

3.3 Implantação e auditabilidade

A solução é containerizada em sete serviços Docker (etcd, MinIO, Milvus-standalone, Attu, PostgreSQL, backend FastAPI com GPU NVIDIA via CUDA 12.1, frontend Nginx) com healthchecks nativos, oferecendo API REST documentada via Swagger UI e SPA HTML/CSS/JS com cinco painéis (Comparar, Ingerir, Treinar, Distribuições, Histórico). Todo fluxo é rastreável: o PostgreSQL armazena os parâmetros gaussianos ativos, o histórico completo de comparações (UUID, caminhos das imagens, escore, LR, $\log_{10}$ LR, interpretação e referência do plot) e o registry de modelos treinados, com EER e flag de ativação — atendendo aos requisitos de **reprodutibilidade e auditabilidade** exigidos pela prática pericial.

4. CONCLUSÃO

O SigForense materializa uma metodologia forense computacional **completa, reprodutível e auditável**, transpondo o estado da arte de comparação facial baseada em embeddings para a documentoscopia caligráfica. As principais contribuições são: (i) a ForensicAwareTriplet, perda métrica que pondera explicitamente o caso intra-writer; (ii) o ForensicPairDataset, amostrador estratificado de pares; (iii) a calibração da LR com DS intra-writer como denominador conservador; (iv) a integração ponta a ponta de seis agentes especializados sob CrewAI; e (v) a explicitação da equivalência operacional entre distância L2 e similaridade cosseno para vetores unitários, garantindo coerência entre treinamento, indexação e laudo. Como trabalhos futuros, propõe-se a ampliação para datasets multi-idiomáticos (GPDS, MCYT, BHSig), explora-

ção de backbones recentes (ConvNeXt V2, DINOv2), substituição das gaussianas paramétricas por modelos não-paramétricos (KDE) e calibração isotônica de LR para mitigar overconfidence em regiões extremas. O sistema posiciona-se como **alternativa célere e assistiva** aos softwares existentes na grafoscopia [12, 14], preservando o protagonismo do perito na decisão final.

REFERÊNCIAS:

[1] CAF — Confiança Automatizada de Fraude. Relatório anual de tentativas de fraude documental no Brasil. 2025. Disponível em: https://www.caf.io/relatorio-fraude-2025. Acesso em: 24 mai. 2026.

[2] KIM, M.; JAIN, A. K.; LIU, X. AdaFace: quality adaptive margin for face recognition. In: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022. p. 18750–18759.

[3] ENFSI — European Network of Forensic Science Institutes. ENFSI Guideline for evaluative reporting in forensic science. Wiesbaden: ENFSI, 2015.

[4] HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016. p. 770–778.

[5] DOSOVITSKIY, A. et al. An image is worth 16×16 words: Transformers for image recognition at scale. In: International Conference on Learning Representations (ICLR), 2021.

[6] DEY, S. et al. SigNet: convolutional Siamese network for writer independent offline signature verification. arXiv preprint arXiv:1707.02131, 2017.

[7] KHOSLA, P. et al. Supervised contrastive learning. In: Advances in Neural Information Processing Systems (NeurIPS), v. 33, 2020. p. 18661–18673.

[8] WANG, J. et al. Milvus: a purpose-built vector data management system. In: Proceedings of the 2021 International Conference on Management of Data (SIGMOD), 2021. p. 2614–2627.

[9] KALERA, M. K.; SRIHARI, S.; XU, A. Offline signature verification and identification using distance statistics. International Journal of Pattern Recognition and Artificial Intelligence, v. 18, n. 7, p. 1339–1360, 2004.

[10] SCHROFF, F.; KALENICHENKO, D.; PHILBIN, J. FaceNet: a unified embedding for face recognition and clustering. In: IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2015. p. 815–823.

[11] AITKEN, C. G. G.; TARONI, F. Statistics and the evaluation of evidence for forensic scientists. 2. ed. Chichester: Wiley, 2004.

[12] FRANCO, J. F.; CARDOSO, A. Uma ferramenta computacional forense para verificação de autenticidade de assinaturas manuscritas através de processamento digital de imagens e redes neurais artificiais. Revista Brasileira de Computação Aplicada, v. 6, n. 2, p. 67–80, 2014.

[13] FALSIFICAÇÃO DE DOCUMENTOS NO BRASIL: panorama geral e perspectivas de combate. Revista de Ciências Jurídicas e Sociais, v. 5, n. 1, 2024. DOI: 10.47595/cjsiurj.v5i1.156.

[14] OLIVEIRA, J. R. et al. Uso de software a favor da grafoscopia: NEGA ACPC, Neuroscript e ScriptAlyzer. Revista Brasileira de Criminalística, v. 8, n. 2, p. 23–34, 2019.

[15] HERMSEN, B. et al. Qual deve ser a razão de verossimilhança de um profissional forense? Forensic Science International, v. 313, 110350, 2020. DOI: 10.1016/j.forsciint.2020.110350.

Locard, E. 1939. *A Investigação Criminal e os Métodos Científicos*. São Paulo: Saraiva.

Longo, P.E. et al. 2011. Avaliação Comparativa de Teste Imunocromatográfico para Identificação Forense de Sangue Humano. *Revista Brasileira de Criminalística 1*(1): 16-21.

FALSIFICAÇÃO DE DOCUMENTOS NO BRASIL PANORAMA GERAL E PERSPECTIVAS DE COMBATE. Revista de Ciências Jurídicas e Sociais, [S. l.], v. 5, n. 1, 2024. DOI: 10.47595/cjsiurj.v5i1.156. Disponível em: https://revista.fiurj.edu.br/cjsiurj/article/view/156. Acesso em: 23 abr. 2026.