T. S. S. Freire, Rev. Bras. Crim. 2026
Edição Especial dos Anais do XXVIII Congresso Nacional de Criminalística

2026
ISSN 2237-9223

REVISTA BRASILEIRA DE CRIMINALÍSTICA

Edição Especial dos Anais do

Diarização não supervisionada de embeddings de voz aplicada à comparação forense de locutores

T. S. S. Freire*

Perícia Forense do Estado do Ceará – Núcleo de Perícia Audiovisual Forense, Fortaleza (CE), Brasil
**Endereço de email para correspondência: tiago.samir@pefoce.ce.gov.br. Tel.: +55-85-99653-5960.*

Palavras-chave: comparação de locutor; embedding de áudio; redução de dimensionalidade; rede neural.

1. INTRODUÇÃO

O exame de comparação locutores constitui uma tarefa complexa e minuciosa no âmbito das perícias audiovisuais. É necessária uma análise de parâmetros acústicos, prosódicos e sociolinguísticos, seguindo protocolos metodológicos criteriosos, para que seja formado um perfil vocal mínimo dos indivíduos investigados. Embora consolidada, essa abordagem é trabalhosa e demanda tempo significativo do perito, especialmente em casos que envolvem grande quantidade de registros de áudio, múltiplos interlocutores e repetições de vozes de um mesmo falante em arquivos distintos.

Na prática pericial, é comum uma única investigação composta por dezenas ou centenas de arquivos, muitos deles com trechos curtos de fala, sobreposição de locutores ou baixa qualidade de gravação. Em diversas situações, a quantidade de fala líquida disponível sequer permite evidenciar um perfil vocal mínimo válido. Se tais registros curtos puderem ser somados como sendo de um mesmo grupo com similaridade validada, a formação do perfil vocal passa a ter resultado com maior eficácia para a posterior comparação.

Diante desse cenário, técnicas modernas de inteligência artificial têm se mostrado ferramentas promissoras para otimizar a triagem preliminar dos registros de áudio. Embeddings de voz, gerados por redes neurais, permitem representar características acústicas de forma compacta e comparável, possibilitando a aplicação de métodos de agrupamento e redução de dimensionalidade para identificar padrões de similaridade entre áudios distintos. Outro benefício é que esses métodos conseguem caracterizar registros mesmo com pouco tempo de fala líquida — a partir de 3 segundos — ampliando a aplicabilidade da triagem inicial em situações nas quais a análise tradicional seria inviável.

Este trabalho apresenta uma abordagem de diarização não supervisionada baseada em embeddings de voz [1], aplicada à etapa preliminar da comparação de locutores. A proposta permite agrupar de forma automatizada registros com maior proximidade acústica, facilitando a identificação de áudios potencialmente relevantes no exame e reduzindo o volume de material para posterior análise perfil e etiquetagem da sociolinguística. Além disso, descreve-se um sistema desenvolvido para operacionalizar essa triagem, integrando extração de embeddings, agrupamento e visualização multidimensional em uma interface prática e acessível.

O objetivo é demonstrar como a utilização de técnicas de aprendizado de máquina pode tornar a triagem inicial das vozes mais eficiente, reduzindo o tempo de trabalho do perito sem comprometer a qualidade analítica, e contribuindo para maior padronização e eficácia dos exames periciais.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Embeddings de voz e representações acústicas

Embeddings de voz são vetores numéricos multidimensionais capazes de codificar propriedades acústicas relevantes de um locutor. Esses vetores são gerados por redes neurais pré-treinadas, como modelos

do tipo ECAPA-TDNN [2], amplamente utilizados na identificação biométrica e verificação de locutor.

Diferentemente dos parâmetros acústicos tradicionais — como formantes, frequência fundamental ou medidas prosódicas — os embeddings sintetizam padrões complexos do sinal de fala em um espaço vetorial que facilita comparações diretas entre diferentes registros e permite comparar áudios mesmo com fala líquida curta.

2.2 Diarização não supervisionada

A diarização de áudio consiste em segmentar um registro de áudio em partes atribuídas a diferentes locutores. No cenário forense, onde não há dados de referência e os registros podem conter ruído ou sobreposição de vozes, abordagens não supervisionadas tornam-se mais adequadas.

Nessa diarização não supervisionada, cada segmento de áudio é convertido em um embedding, e a separação entre grupos de locutores é dada partir da similaridade matemática entre esses vetores. Assim, segmentos pertencentes ao mesmo indivíduo tendem a formar agrupamentos naturais no espaço vetorial.

2.3 Agrupamento e métricas de similaridade

A etapa de agrupamento (*clustering*) é muito importante na diarização não supervisionada. Métodos de agrupamento, como k-means [3], permitem organizar embeddings em grupos coerentes. A proximidade entre vetores pode ser avaliada por métricas como distância euclidiana ou similaridade cosseno. Essas técnicas auxiliam na identificação de registros com maior proximidade acústica, facilitando a triagem dos áudios.

2.4 Redução de dimensionalidade

Embeddings de voz costumam possuir centenas de dimensões, o que dificulta sua visualização e análise. Técnicas de redução de dimensionalidade, como PCA (Principal Component Analysis) [4], t-SNE (t-Distributed Stochastic Neighbor Embedding) [5] e UMAP (Uniform Manifold Approximation and Projection) [6], permitem projetar os vetores em espaços bidimensionais ou tridimensionais, preservando relações estruturais relevantes e facilitando a visualização dos agrupamentos formados e interpretação dos padrões de similaridade entre os áudios investigados.

3. METODOLOGIA

O trabalho representa um estudo analítico-descritivo, com abordagem experimental, voltado à avaliação da aplicabilidade de técnicas de diarização não supervisionada para triagem preliminar em exames de comparação de locutores. A presente análise foi conduzida entre janeiro e março de 2026.

3.1 Material avaliado

Foram utilizados registros de áudio contendo diferentes falantes, homens e mulheres, com durações variadas de fala líquida. O conjunto incluiu áudios de quantidade de tempo variados (entre 5 e 20 segundos), simulando cenários comuns na rotina pericial, incluindo áudios com fala líquida insuficiente para a construção de um perfil vocal minimamente aceitável.

3.2 Extração dos embeddings, diarização e visualização do agrupamento

Cada arquivo de áudio foi processado por uma rede neural do tipo ECAPA-TDNN [2], pré-treinada para verificação de locutor. O modelo gera, para cada registro, um vetor de 192 dimensões, representando características relevantes do sinal de fala.

Os embeddings foram normalizados e submetidos a métodos de agrupamento não supervisionado, para identificar conjuntos com maior similaridade acústica. A proximidade entre vetores foi avaliada por métricas como distância euclidiana e similaridade cosseno. A definição do número ideal de grupos (clusters) considerou medidas de coesão intragrupal, como o coeficiente de silhueta.

Para facilitar a interpretação dos agrupamentos, os embeddings foram projetados em espaços 2D e 3D por meio de técnicas de redução de dimensionalidade, como PCA [4], t-SNE [5] e UMAP [6]. As representações resultantes permitiram visualizar a separação entre locutores e avaliar a consistência dos agrupamentos formados.

3.3 Etapas da análise

O processo metodológico utilizado compreende as seguintes etapas:

- Pré-processamento dos arquivos de áudio;
- Extração dos embeddings com 192 dimensões;
- Normalização dos vetores;
- Cálculo de similaridade;
- Agrupamento não supervisionado;
- Projeção visual em 2D/3D;
- Interpretação dos grupos criados.

Essas etapas foram posteriormente inseridas em um sistema computacional, permitindo sua aplicação prática na triagem inicial de registros de áudio para otimização dos exames de comparação de locutores.

4. SISTEMA DESENVOLVIDO

Com o objetivo de operacionalizar a triagem preliminar dos áudios, foi desenvolvido um sistema computacional que executa no carregamento dos arquivos: a extração dos embeddings de 192 dimensões por meio do modelo ECAPA-TDNN [2]; o agrupamento não supervisionado; e a apresentação visual dos resultados. A aplicação foi implementada em ambiente Python, utilizando bibliotecas próprias para processamento de áudio e visualização multidimensional.

Após a geração dos embeddings, os vetores são normalizados e submetidos a algoritmos de agrupamento, permitindo identificação das similaridades por área. Em seguida, a redução de dimensionalidade é aplicada, criando as representações bidimensionais ou tridimensionais, à critério do usuário, que facilitam a interpretação visual dos grupos.

A interface básica foi gerada em *Streamlit*, possibilitando ao perito carregar os áudios, visualizar os embeddings de cada um dos arquivos, ajustar parâmetros de número de clusters, escolher técnica de redução e observar as respostas do sistema. A aplicação foi criada para auxiliar especificamente essa etapa inicial do exame de comparação de locutor, permitindo ao perito otimizar seu trabalho de formação de perfil vocal com foco apenas nos registros potencialmente relevantes e reduzindo o tempo total de análise.

5. RESULTADOS

A avaliação do número ideal de clusters foi realizada por meio do coeficiente de silhueta, calculado para valores de k entre 2 e 10. A Figura 1 apresenta a curva resultante, na qual se observa um pico principal em k = 4, indicando essa como a melhor separação entre grupos. Um segundo pico menor aparece em k = 8, porém com menor estabilidade e interpretação diversa, reforçando a escolha de quatro clusters como solução mais adequada.

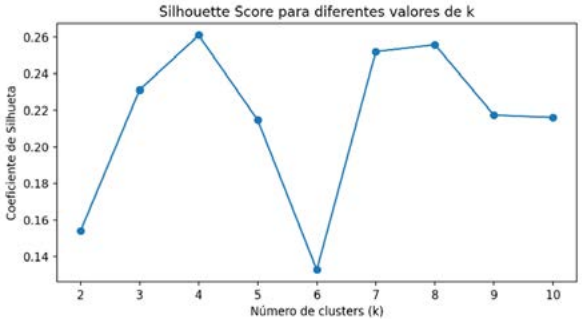


Figura 1. Curva de silhueta para valores de K.

Em seguida, os embeddings de 192 dimensões foram projetados em duas dimensões utilizando as três técnicas distintas de redução de dimensionalidade. As Figuras 2, 3 e 4 apresentam as projeções obtidas para k = 4, usando PCA, UMAP e t-SNE, respectivamente. Em todas as técnicas, a estrutura dos dados se manteve consistente, revelando quatro grupos naturais:

- M1 gerou um cluster isolado;
- M2 gerou outro cluster isolado;
- H2 apresentou características acústicas suficientemente distintas para compor um cluster próprio;
- H1 e H3 permaneceram agrupados no mesmo cluster em todas as projeções.

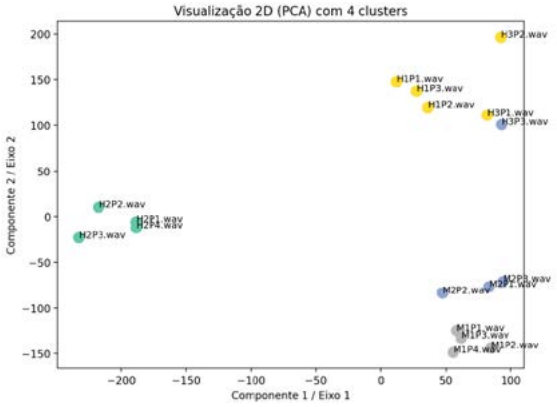


Figura 2. Resultado PCA dos embeddings para k=4.

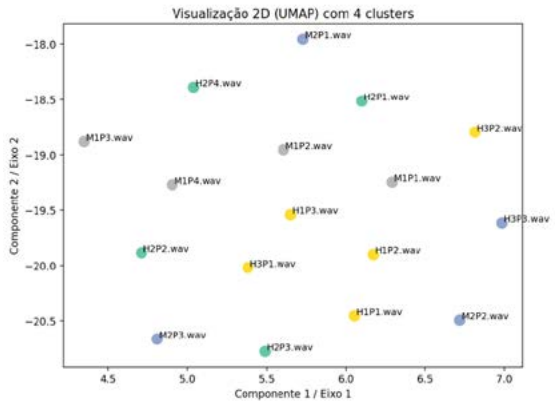


Figura 3. Resultado UMAP dos embeddings para k=4.

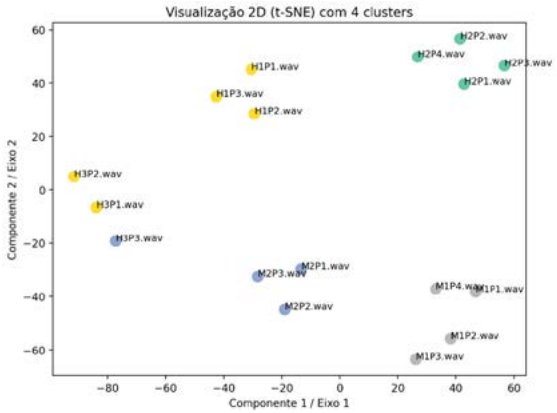


Figura 4. Resultado t-SNE dos embeddings para k=4.

Essa convergência entre métodos reforça a robustez da solução com quatro clusters, independentemente da técnica de projeção utilizada. Além disso, observou-se que mesmo trechos curtos de fala líquida (entre 1 e 5 se-

gundos) foram suficientes para gerar embeddings consistentes, capazes de preservar a separação entre locutores. Esse comportamento reforça a aplicabilidade da abordagem em cenários forenses com áudio limitado.

Quando o número de clusters foi forçado para k = 5, observou-se fragmentação artificial dos grupos, incluindo clusters com poucos pontos ou até mesmo um único elemento, especialmente nas projeções t-SNE. Esse comportamento caracteriza overclustering, indicando que a estrutura natural dos dados avaliados não comporta cinco grupos distintos, apesar da quantidade real conhecida de locutores.

6. DISCUSSÃO

Embora o conjunto analisado contenha cinco locutores distintos (três homens e duas mulheres), a análise de silhueta indicou uma solução ótima em quatro clusters, resultado confirmado pelas projeções em PCA, UMAP e t-SNE. Em todas as técnicas, observou-se a formação consistente de quatro grupos acústicos naturais, nos quais H1 e H3 foram agrupados em um mesmo cluster, sugerindo maior similaridade vocal entre eles, enquanto M1, M2 e H2 formaram grupos distintos.

A tentativa de utilizar k = 5 resultou em clusters menores e menos estáveis, incluindo divisões artificiais e até grupos com apenas um ponto, caracterizando overclustering. Assim, a solução com k = 4 mostrou-se mais estável, interpretável e coerente com a estrutura natural dos dados.

Mesmo com trechos curtos de fala líquida (1 a 5 segundos), os embeddings mantiveram consistência suficiente para preservar a separação entre locutores, reforçando a aplicabilidade da abordagem em cenários forenses com áudio limitado. Esses resultados indicam que a diarização não supervisionada pode otimizar a triagem inicial dos exames de comparação de locutor, permitindo ao perito concentrar esforços nos registros mais relevantes, sem substituir a análise técnica tradicional.

7. CONCLUSÕES

Os resultados obtidos evidenciam que a utilização de embeddings de voz e técnicas de agrupamento não supervisionado pode auxiliar de forma eficaz a triagem preliminar dos exames. Apesar da presença de cinco indivíduos distintos no conjunto analisado, a estrutura natural dos dados revelou quatro grupos acústicos, com H1 e H3 apresentando forte similaridade vocal. A solução com k = 4 mostrou-se mais estável e coerente do que k = 5, que gerou clusters artificiais e pouco interpretáveis.

Mesmo com trechos curtos de fala líquida, os embeddings mantiveram consistência suficiente para distinguir locutores, reforçando a aplicabilidade da abordagem em casos reais composto por comunicação comum de áudio entre indivíduos investigados. Assim, o sistema desenvolvido contribui na análise pericial dos áudios, reduzindo o tempo de uma etapa preliminar fundamental da perícia e direcionando o perito aos registros evidenciados como mais relevantes, sem substituir a avaliação técnica especializada do exame.

AGRADECIMENTOS

Agradeço inicialmente à organização do XXVIII Congresso Nacional de Criminalística pelo fomento na troca de conhecimentos com os trabalhos científicos e inovações de toda a classe pericial do País. Agradeço à Perícia Forense do Estado do Ceará (PEFOCE) e aos colegas peritos criminais e auxiliares de perícia do Núcleo de Perícia Audiovisual Forense (NUPAF) pelo apoio técnico durante o desenvolvimento deste trabalho. Agradeço também a todos que contribuíram voluntariamente com as gravações de áudio, discussões, testes e validações preliminares do sistema, possibilitando a consolidação dos resultados buscados e apresentados neste trabalho. Por fim, agradeço igualmente ao Sindicato dos Peritos Oficiais do Estado do Ceará por toda assistência e encorajamento no desenvolvimento científico da categoria.

REFERÊNCIAS BIBLIOGRÁFICAS

[1] Anguera, X.; Bozonnet, S.; Evans, N.; Fredouille, C.; Friedland, G.; Vinyals, O. *Speaker Diarization: A Review of Recent Research*. IEEE Transactions on Audio, Speech, and Language Processing, v. 20, n. 2, p. 356–370, 2012.

[2] Desplanques, B.; Thienpondt, J.; Demuynck, K. *ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN-Based Speaker Verification*. Interspeech, 2020.

[3] Lloyd, S. *Least Squares Quantization in PCM*. IEEE Transactions on Information Theory, v. 28, n. 2, p. 129–137, 1982.

[4] Jolliffe, I. T. *Principal Component Analysis*. Springer Series in Statistics, Springer, 2002.

[5] van der Maaten, L.; Hinton, G. *Visualizing Data using t-SNE*. Journal of Machine Learning Research, v. 9, p. 2579–2605, 2008.

[6] McInnes, L.; Healy, J.; Melville, J. *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. arXiv:1802.03426, 2018.