2026
ISSN 2237-9223

REVISTA BRASILEIRA DE CRIMINALÍSTICA

Edição Especial dos Anais do

Análise comparativa entre fotogrametria digital e 3D Gaussian Splatting para documentação forense de vestígios veiculares

F. A. Silva[a,*], A. R. Cukla[b], S. G. S. Alcalá[c]

[a]*Superintendência de Polícia Técnico-Científica, Goiânia (GO), Brasil*

[b]*Universidade Federal de Santa Maria, Santa Maria (RS), Brasil*

[c]*Universidade Federal de Goiás, Goiânia (GO), Brasil*

**Endereço de e-mail para correspondência: fernando.esilva@goias.gov.br. Tel.: +55-64-99266-8503.*

Palavras-chave: COLMAP; fotogrametria; Gaussian Splatting; perícia veicular; reconstrução 3D

1. INTRODUÇÃO

A documentação técnica de vestígios veiculares é etapa fundamental para a reconstrução da dinâmica de acidentes de trânsito [1]. A precisão e a fidelidade desse registro são determinantes para a elucidação de causas, a estimativa de velocidades e a correlação com lesões em vítimas. Tradicionalmente, a fotogrametria digital de curto alcance, baseada no paradigma *Structure-from-Motion* (SfM) seguido de *Multi-View Stereo* (MVS), consolidou-se como a ferramenta padrão para este fim, em virtude do seu custo-benefício e da capacidade de gerar modelos tridimensionais densos a partir de coleções de imagens [2].

Não obstante sua eficácia, o fluxo de trabalho fotogramétrico apresenta limitações operacionais significativas no contexto da rotina pericial. A etapa de densificação da nuvem de pontos (MVS), implementada em *softwares* como o COLMAP, é computacionalmente onerosa, frequentemente demandando horas de processamento mesmo em *hardware* de alto desempenho [3]. Esse gargalo temporal conflita com a necessidade de liberação rápida do bem periciado e com a otimização dos recursos humanos e computacionais das unidades de perícia. Adicionalmente, superfícies desafiadoras comuns em veículos automotores - tais como vidros laminados, pintura metálica especular e superfícies de baixa textura - tendem a gerar artefatos de reconstrução ou lacunas na nuvem de pontos, comprometendo a fidelidade visual e, em alguns casos, a precisão geométrica do modelo, conforme discutido em estudos sobre superfícies reflexivas [4].

Recentemente, a literatura de visão computacional apresentou o *3D Gaussian Splatting* (3DGS) [5]. Embora o 3DGS tenha surgido como alternativa aos métodos neurais implícitos, o presente estudo concentra-se em compará-lo com a abordagem fotogramétrica SfM-MVS tradicional, que constitui o padrão atual nas perícias. O 3DGS representa a cena de forma explícita por meio de primitivas gaussianas anisotrópicas, conferindo duas vantagens para a documentação forense: treinamento significativamente mais rápido (minutos, em vez de horas) e renderização fotorrealista em tempo real. Implementações como o *framework* Nerfstudio tornaram essa tecnologia acessível para validação experimental [6].

O objetivo deste trabalho é realizar uma comparação experimental controlada entre o pipeline SfM-MVS e o 3DGS na documentação forense de vestígios veiculares, utilizando o mesmo conjunto de imagens de um caso real de colisão veicular, avaliando simultaneamente acurácia dimensional por meio do Erro Médio Absoluto (MAE) e fidelidade visual por meio das métricas PSNR (*Peak Signal-to-Noise Ratio*), SSIM (*Structural Similarity Index Measure*) e LPIPS (*Learned Perceptual Image Patch Similarity*), em infraestrutura de nuvem de baixo custo.

Os objetivos específicos são:

- quantificar a redução no tempo de processamento e no volume de dados gerados pelo 3DGS em re-

lação ao COLMAP;

- avaliar a acurácia dimensional dos modelos por meio do MAE;
- aferir a fidelidade visual utilizando PSNR, SSIM e LPIPS.

As principais contribuições científicas e periciais deste artigo incluem:

- validação métrica e visual simultânea do 3DGS em contexto forense veicular real, com dados de um acidente;
- demonstração da viabilidade de execução de ambos os fluxos em infraestrutura de nuvem computacional de baixo custo, eliminando a necessidade de hardware local dedicado;
- quantificação dos ganhos operacionais (tempo, volume de dados, custo) que apoiam a tomada de decisão sobre a adoção do 3DGS na rotina pericial.

2. FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS

2.1. Fotogrametria SfM-MVS

O SfM estima as poses das câmeras (R_i, t_i) e a estrutura esparsa (X_j) por Ajuste de Feixes, minimizando o erro de reprojeção [2]:

$$E = \sum_{i,j} \rho\left(\left\|\pi(R_i, t_i, K, X_j) - x_{ij}\right\|^2\right) \quad (1)$$

onde $\pi(\cdot)$ é a projeção perspectiva, K a matriz intrínseca da câmera e ρ a função robusta de Huber. Os pontos de interesse são detectados por SIFT [7] e emparelhados entre imagens para estabelecer correspondências. Após o ajuste global das câmeras, o MVS densifica a geometria por algoritmos como PatchMatch Stereo, maximizando a consistência fotométrica entre múltiplas visões [3].

2.2. 3D Gaussian Splatting

O 3DGS [5] modela a cena como N primitivas gaussianas anisotrópicas. Cada primitiva é parametrizada por um centroide μ, uma covariância Σ, opacidade α e harmônicos esféricos para a cor. A matriz de covariância é fatorada em uma matriz de rotação R e uma matriz de escala S conforme:

$$\Sigma = RSS^{\top}R^{\top} \quad (2)$$

Durante a renderização, cada gaussiana é projetada no plano da imagem. A covariância 2D resultante é obtida pela propagação:

$$\Sigma' = JW\Sigma W^{\top}J^{\top} \quad (3)$$

Finalmente, a cor de cada pixel é calculada via alpha-compositing ordenado por profundidade:

$$C = \sum_i c_i \alpha'_i \prod_{j=1}^{i-1}\left(1 - \alpha'_j\right) \quad (4)$$

Otimizado com Adam e densificação adaptativa, o 3DGS converge em minutos, evitando amostragens volumétricas.

2.3. Métricas de Qualidade Visual

O PSNR (*Peak Signal-to-Noise Ratio*) mede a razão entre o valor máximo de intensidade e o erro quadrático médio (MSE). O SSIM (*Structural Similarity Index Measure*) [8] avalia luminância, contraste e estrutura em janelas locais:

$$\mathrm{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (5)$$

O LPIPS (*Learned Perceptual Image Patch Similarity*) [9] computa a distância perceptual no espaço de características de uma rede convolucional pré-treinada, sendo considerado a métrica mais diagnóstica para modelos de síntese neural.

2.4. Trabalhos Relacionados

Buck et al. [10] integraram fotogrametria, *laser scanning* e digitalização 3D para reconstrução de cenas de crime. Mildenhall et al. [11] introduziram o NeRF, alcançando renderizações fotorrealistas, porém apresentando treino lento. Kerbl et al. [5] reduziram esse tempo para minutos com o 3DGS, enquanto Barron et al. [12] estabeleceram *benchmarks* (PSNR, SSIM, LPIPS). Maneli e Isafiade [13] apontaram a falta de avaliações integradas na literatura. Nenhum trabalho anterior avaliou 3DGS em contexto veicular real.

3. MATERIAIS E MÉTODOS

3.1. Descrição do Caso Pericial e Aquisição das Imagens

Utilizou-se um Fiat Mobi 2022 após colisão lateral real, com estilhaçamento de vidros e deformação da porta e paralama. A captura ocorreu em 27/12/2025, sob luz solar plena.

As imagens foram adquiridas com câmera Canon EOS R7 (32,5 MP, lente 18 mm) em f/4.5, 1/500s, ISO 100. Realizaram-se três órbitas manuais com sobreposição >80%. Foram adquiridas 327 imagens (4800 × 3200 pixels) em 4 minutos (13h56–14h00). Para otimização, todas foram redimensionadas para 2400 × 1600 pixels (3,8 MP) antes do envio à nuvem, resultando em um conjunto de 373 MB.

3.2. Infraestrutura Computacional (Nuvem)

Utilizou-se instância Vast.ai (Tabela 1), com custo de USD 0,17/h.

Tabela 1. Especificações da instância utilizada.

Componente	Especificação
GPU	NVIDIA GeForce RTX 3090 (24 GB VRAM)
CPU	AMD EPYC 7542 32-Core (15 vCPUs alocados)
RAM	64,2 GB
Armazenamento	150 GB SSD
Custo	USD 0,17 / hora

3.3. Fluxo de Trabalho A: Fotogrametria Clássica (COLMAP)

O pipeline tradicional foi executado no COLMAP versão 4.1.0.dev0 (modo automático, nível *HIGH*) e incluiu: extração SIFT (8192 *keypoints*/imagem), correspondência exaustiva (RANSAC), *Bundle Adjustment*, MVS via *PatchMatch* com fusão geométrica e *Poisson Surface Reconstruction*.

Os tempos foram registrados a partir dos *logs* nativos. O modelo final gerou malha texturizada com 4.056.010 vértices e 8.032.060 faces (196 MB) e nuvem densa com 13.306.108 pontos (342 MB).

3.4. Fluxo de Trabalho B: 3D Gaussian Splatting (Nerfstudio)

O modelo 3DGS foi treinado com o *framework* Nerfstudio versão 1.1.5, método splatfacto-big. O pipeline executou internamente COLMAP 3.11.1 para estimação de poses. O treinamento foi conduzido por 30.000 iterações com hiperparâmetros padrão. O modelo final no formato .ply contém 2.824.971 gaussianas, ocupando 668 MB.

3.5. Pós-Processamento e Correção de Escala

Uma vez que os modelos gerados por SfM e 3DGS possuem escala arbitrária, foi necessária a correção métrica previamente à extração das medidas. Selecionou-se como referência a distância entre eixos do veículo Fiat Mobi, cujo valor nominal de 2307 mm foi obtido do manual do fabricante [14]. A mesma distância foi medida nos modelos COLMAP e 3DGS em suas unidades nativas, utilizando as ferramentas de medição dos softwares MeshLab (versão 2023.12) e Supersplat, respectivamente. A partir desses valores, foram calculados os fatores de escala globais de 1,0378 para o modelo COLMAP e 1,0163 para o modelo 3DGS. Todas as demais medições foram convertidas para o sistema métrico real por meio da multiplicação por esses fatores. Para facilitar o processo de medição, os modelos foram rotacionados e alinhados visualmente nos respectivos *softwares*, sem que houvesse qualquer alteração geométrica, remoção de pontos ou edição da estrutura original dos arquivos.

3.6. Métricas de Avaliação

A comparação entre os dois fluxos de trabalho foi estruturada em quatro eixos de análise:

- Desempenho Temporal e Custo: Registro dos tempos de cada etapa a partir dos *logs* do COLMAP e do Nerfstudio, com cálculo do custo estimado em nuvem com base no valor da instância (USD 0,17/h).
- Volume de Dados Gerados: Quantificação do espaço em disco ocupado pelos arquivos intermediários e pelos modelos finais de cada *pipeline*.
- Qualidade Visual Objetiva: Foram renderizadas 32 imagens a partir das poses originais das câmeras (*test set*) utilizando o módulo ns-eval do Nerfstudio. Essas imagens sintéticas foram comparadas com as fotografias reais correspondentes, calculando-se as métricas PSNR, SSIM, LPIPS.
- Precisão Métrica: Após correção de escala, foram medidas cinco distâncias de referência nos modelos finais (comprimento total, altura total, altura da porta dianteira, largura do para-brisa e distância entre eixos), utilizando as ferramentas de medição do MeshLab e do Supersplat. Os valores foram comparados com o *ground truth* para cálculo do Erro Absoluto e do Erro Médio Absoluto (MAE).

4. RESULTADOS E DISCUSSÃO

4.1. Desempenho Temporal e Custo Computacional

A Tabela 2 detalha o custo temporal de cada *pipeline*. O Método A (COLMAP Completo) demandou 7h13min, com a etapa de densificação respondendo por 77% desse tempo. Em contrapartida, o Método B (Splatfacto-big) concluiu todo o fluxo - incluindo

SfM e treinamento do modelo 3DGS - em apenas 1 hora e 39 minutos.

O tempo de treinamento do 3DGS (54 minutos e 57 segundos) é o principal fator de aceleração. No total, o Nerfstudio foi aproximadamente 4,4 vezes mais rápido que o COLMAP, representando uma redução de 77% no tempo total de processamento. Com o custo da instância de computação em nuvem com GPU dedicada (USD 0,17/h), o processamento completo do 3DGS custou cerca de USD 0,28, enquanto o COLMAP MVS custou aproximadamente USD 1,22.

Tabela 2. Comparativo de desempenho temporal (Instância computação em nuvem com RTX 3090).

Etapa / Pipeline	COLMAP (A)	Nerfstudio (B)
1. SfM (Extração + *Matching* + BA)	68,1 min	40,55 min
2. MVS ou 3DGS	331,5 min (MVS)	54,9 min (Treinamento)
3. Etapas adicionais (Undistortion/Fusion/Export)	33,4 min	~ 4 min (Caching)
TEMPO TOTAL (Pós-Captura)	433 min	99,45 min
Custo Estimado (USD 0,17/h)	~ USD 1,22	~ USD 0,28

4.2. Volume de Dados

A Tabela 3 apresenta o volume de dados gerados por cada pipeline. O COLMAP MVS produziu aproximadamente 39,5 GB de dados, incluindo arquivos intermediários. No pipeline 3DGS, o conjunto completo de dados (excluindo as imagens originais) totalizou 3,38 GB, dos quais 668 MB correspondem ao modelo final (.ply) e o restante a checkpoints e arquivos de processamento do COLMAP interno.

Tabela 3. Comparativo do volume de dados gerados.

Pipeline	Arquivos Intermediários	Modelo Final (Nuvem/Malha)	Total Gerado
COLMAP (Método A)	~ 39 GB	196 MB (Malha) + 342 MB (Nuvem)	~ 39,5 GB*
Splatfacto-big (Método B)	~ 2,74 GB	668 MB (splat.ply)	~ 3,38 GB*

*Não incluídos 373 MB das imagens de entrada.

4.3. Qualidade Visual e Fotorrealismo

A Tabela 4 apresenta os resultados da avaliação visual quantitativa para as 32 poses renderizadas. O modelo 3DGS atingiu um PSNR médio de 20,80 dB e SSIM de 0,695. A métrica LPIPS de 0,280 indica uma dissimilaridade perceptual moderada-baixa, consistente com a percepção visual de um modelo navegável de alta qualidade. A taxa de renderização obtida foi de aproximadamente 20 FPS, assegurando uma experiência de navegação fluida.

Tabela 4. Métricas objetivas de qualidade visual (3DGS vs. imagem real redimensionada).

Métrica	Média + Desvio Padrão (32 Poses)
PSNR (dB)	20,8 ± 2,64
SSIM	0,695 ± 0,091
LPIPS (↓)	0,28 ± 0,07
FPS de Renderização	19,57 ± 3,63

A Figura 1 ilustra qualitativamente a reconstrução de uma região de interesse (estilhaçamento do parabrisa e deformação da porta). Observa-se que o modelo 3DGS (Figura 1C) preserva a nitidez das bordas do vidro estilhaçado e reproduz com fidelidade as variações de brilho na carroceria. A malha texturizada do COLMAP (Figura 1B), embora geometricamente precisa, apresenta borramento (*blurring*) nas áreas de baixa textura da carroceria e pequenas descontinuidades na região do vidro, artefatos comuns em reconstruções MVS de superfícies especulares, conforme evidenciado em estudos com superfícies reflexivas [4].



Figura 1. Comparativo visual da região do para-brisa e porta dianteira. (A) Fotografia original; (B) Malha texturizada COLMAP; (C) Renderização 3DGS (Splatfacto).

4.4. Precisão Métrica e Validação Forense

A Tabela 5 consolida a análise dos erros dimensionais após a aplicação dos fatores de escala globais calculados a partir da distância entre eixos. O modelo COLMAP apresentou MAE de 14,5 mm, valor compatível com a precisão típica de reconstruções fotogramétricas utilizadas rotineiramente em perícias veiculares. Já o 3DGS obteve MAE de 21,5 mm. Embora ligeiramente superior, essa diferença é aceitável para a documentação visual e para medições preliminares de macrovestígios, especialmente considerando os ganhos expressivos em tempo de processamento e qualidade visual. A superioridade métrica do MVS era esperada, pois o pipeline otimiza explicitamente consistência geométrica, enquanto o 3DGS prioriza fidelidade visual.

5. DISCUSSÃO

5.1. Eficiência Operacional e Custo-Benefício

A redução no tempo total de processamento - de aproximadamente 7 horas e 13 minutos no Fluxo A para 1 hora e 39 minutos no Fluxo B - representa um avanço significativo para a produtividade da perícia. Na rotina pericial, a captura das imagens em campo é seguida pela liberação do veículo ou local, e o processamento dos dados ocorre posteriormente em ambiente de escritório. Nesse contexto, a capacidade de obter um modelo 3D navegável em menos de duas horas - em contraste com a espera de um dia inteiro ou processamento noturno exigido pelo MVS - permite que o perito analise os vestígios, realize medições preliminares e prepare a documentação visual ainda no mesmo expediente. Essa agilidade impacta diretamente o fluxo de trabalho, reduzindo o tempo ocioso entre a captura e a análise efetiva dos dados.

Além disso, o custo computacional total de apenas USD 0,28 para o Fluxo B demonstra que a barreira financeira para adoção de tecnologias avançadas de reconstrução 3D pode ser superada com o uso estratégico de recursos de nuvem sob demanda, eliminando a necessidade de investimento inicial em *hardware* local de alto desempenho.

O volume total de dados gerados pelo 3DGS (3,38 GB) é aproximadamente 11,7 vezes menor que os 39,5 GB do pipeline MVS, representando uma redução de cerca de 91%. Para instituições periciais que lidam com milhares de casos anualmente, essa economia é significativa: o custo de armazenamento e a complexidade da gestão de grandes volumes de dados são fatores críticos. O modelo 3DGS, por ser compacto e visualizável em navegadores web, simplifica sobremaneira o arquivamento digital e o compartilhamento de evidências entre peritos, assistentes técnicos e operadores do Direito.

5.2. Fidelidade Visual e Comunicação da Prova

A superioridade visual do 3DGS, evidenciada tanto pelas métricas objetivas (PSNR, SSIM, LPIPS) quanto pela inspeção qualitativa (Figura 1), tem implicações diretas na fase processual. Modelos mais nítidos e fotorrealistas facilitam a comunicação dos achados periciais a juízes, promotores e jurados leigos, que podem compreender melhor a dinâmica do impacto através de navegação virtual interativa [13]. A capacidade de renderização em tempo real (~20 FPS) permite uma exploração interativa da cena, algo inviável com as pesadas malhas geradas pelo MVS.

Ademais, o bom desempenho do 3DGS em superfícies reflexivas (vidro estilhaçado e carroceria) e de baixa textura mitiga uma das fraquezas clássicas da fotogrametria tradicional, que frequentemente resultam em lacunas e artefatos [4]. Essa robustez é particularmente valiosa na documentação de veículos modernos, que empregam extensivamente materiais com essas características.

Tabela 5. Erro absoluto em distâncias de referência e Erro Médio Absoluto (MAE).

Dimensão	Ground Truth (mm)	COLMAP (bruto)	COLMAP (corrigido mm)	COLMAP Erro (mm)	3DGS (bruto)	3DGS (corrigido mm)	3DGS Erro (mm)
Comprimento total	3566	3,464	3595	29	3,55	3608	42
Altura total	1523	1,473	1529	6	1,48	1504	-19
Altura da porta dianteira	1070	1,04	1079	9	1,07	1087	17
Largura do para-brisa (topo)	1130	1,102	1144	14	1,12	1138	8
Erro Médio Absoluto (MAE)	--	--	--	14,5	--	--	21,5

5.3. Acurácia Métrica e Limitações

A precisão métrica do 3DGS (MAE = 21,5 mm), embora ligeiramente inferior à do COLMAP MVS (MAE = 14,5 mm), é comparável à de métodos fotogramétricos já consolidados na prática pericial. Isso demonstra que o 3DGS oferece acurácia suficiente para a documentação forense veicular, em especial quando se prioriza a agilidade e a renderização fotorrealista. É fundamental ressaltar que a acurácia do 3DGS é condicionada à qualidade da etapa preliminar de SfM e, crucialmente, à correta aplicação de um fator de escala baseado em uma referência física confiável. A ausência de um padrão de escala na cena (ex.: régua ou alvo calibrado) introduz uma etapa de pós-processamento que, embora viável, depende da existência de medidas conhecidas no objeto periciado.

A extração de uma malha 3D contínua e metricamente precisa a partir da representação por gaussianas ainda é um desafio técnico e uma área ativa de pesquisa [5]. Para aplicações que exigem a extração de perfis de deformação complexos ou a realização de simulações de elementos finitos, a malha gerada pelo MVS ainda é a ferramenta mais adequada.

5.4. Limitações do Estudo e Perspectivas

Este estudo apresenta algumas limitações que devem ser consideradas. A avaliação foi realizada em um único cenário de iluminação (sol pleno) e com um único veículo. Investigações futuras são necessárias para avaliar a robustez do 3DGS em condições adversas de campo, como baixa luminosidade noturna, chuva ou sombras duras. Além disso, a validação métrica baseou-se em um conjunto limitado de cinco distâncias; estudos com maior número de medições e com a inclusão de um *ground truth* denso (ex.: *laser scanner*) podem refinar a análise da acurácia geométrica do método.

Apesar dessas limitações, os achados fornecem evidências robustas de que o 3DGS é promissor para ser incorporado ao fluxo de trabalho pericial como uma ferramenta complementar de alta produtividade.

6. CONCLUSÃO

Este trabalho apresentou uma comparação experimental direta entre o *pipeline* tradicional de fotogrametria SfM-MVS (COLMAP) e o método emergente *3D Gaussian Splatting* (Nerfstudio/splatfacto-big) para a documentação de vestígios veiculares, utilizando infraestrutura de nuvem computacional de baixo custo. Os resultados demonstram vantagens expressivas do 3DGS em todos os aspectos operacionais avaliados: redução de 77% no tempo de processamento (de 7h13min para 1h39min), redução de 91% no volume total de dados gerados (de 39,5 GB para 3,38 GB) e custo computacional total de apenas USD 0,28. A qualidade visual do modelo 3DGS mostrou-se superior à da malha MVS, especialmente em superfícies desafiadoras como vidros estilhaçados e superfícies de baixa textura, com renderização fluida a aproximadamente 20 quadros por segundo. A precisão métrica do 3DGS (MAE = 21,5 mm), quando devidamente escalonada, é plenamente compatível com as exigências da documentação de macro vestígios em acidentes de trânsito. Recomenda-se o 3DGS como fluxo preferencial para documentação visual e medições, reservando-se o COLMAP MVS apenas quando forem necessárias malhas sólidas para simulações.

7. DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

Os autores declaram que, na elaboração deste trabalho, foram utilizadas as seguintes ferramentas de Inteligência Artificial Generativa: DeepSeek-V4 Pro (na revisão da literatura, verificação de citações e referências, revisão gramatical e adequação ao template); Gemini (Google) e DeepSeek (suporte para a configuração de ambientes virtuais e instâncias na plataforma Vast.ai). O conteúdo final, incluindo a

exatidão das informações, é de inteira responsabilidade dos autores, em conformidade com a Portaria CNPq nº 2.664/2026.

REFERÊNCIAS BIBLIOGRÁFICAS

[1] V. Berezowski; X. Mallett; I. Moffat. Geomatic techniques in forensic science: A review. *Sci. Justice* 60: 99-107 (2020).

[2] J.L. Schönberger; J.M. Frahm. Structure-from-Motion Revisited. Anais do *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 4104-4113 (2016).

[3] J.L. Schönberger; E. Zheng; J.M. Frahm; M. Pollefeys. Pixelwise View Selection for Unstructured Multi-View Stereo. Anais do *European Conference on Computer Vision (ECCV)*. 501-518 (2016).

[4] K. Bartoš; K. Pukanská; L. Kseňak; J. Gašinec; P. Bella. Cross-Polarized SfM Photogrammetry for the Spatial Reconstruction of Challenging Surfaces, the Case Study of Dobšiná Ice Cave (Slovakia). *Remote Sens.* 15: 4481 (2023).

[5] B. Kerbl; G. Kopanas; T. Leimkühler; G. Drettakis. 3D Gaussian Splatting for Real-Time Radiance Field Rendering. *ACM Trans. Graph.* 42: 139 (2023).

[6] M. Tancik; E. Weber; E. Ng; R. Li; B. Yi; J. Kerr; T. Wang; A. Kristoffersen; J. Austin; K. Salahi; A. Ahuja; D. McAllister; A. Kanazawa. Nerfstudio: A Modular Framework for Neural Radiance Field Development. Anais do *ACM SIGGRAPH 2023 Conference Proceedings*. 1-12 (2023).

[7] D.G. Lowe. Distinctive Image Features from Scale-Invariant Keypoints. *Int. J. Comput. Vis.* 60: 91-110 (2004).

[8] Z. Wang; A.C. Bovik; H.R. Sheikh; E.P. Simoncelli. Image quality assessment: from error visibility to structural similarity. *IEEE Trans. Image Process.* 13: 600-612 (2004).

[9] R. Zhang; P. Isola; A.A. Efros; E. Shechtman; O. Wang. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric. Anais do *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 586-595 (2018).

[10] U. Buck; S. Naether; B. Räss; C. Jackowski; M.J. Thali. Accident or homicide - Virtual crime scene reconstruction using 3D methods. *Forensic Sci. Int.* 225: 75-84 (2013).

[11] B. Mildenhall; P.P. Srinivasan; M. Tancik; J.T. Barron; R. Ramamoorthi; R. Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. Anais do *European Conference on Computer Vision (ECCV 2020)*. 405-421 (2020).

[12] J.T. Barron; B. Mildenhall; D. Verbin; P.P. Srinivasan; P. Hedman. Mip-NeRF 360: Unbounded Radiance Fields. Anais do *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 5470-5479 (2022).

[13] M.A. Maneli; O.E. Isafiade. 3D Forensic Crime Scene Reconstruction Involving Immersive Technology: A Systematic Literature Review. *IEEE Access* 10: 88821-88857 (2022).

[14] FIAT. *Manual do Proprietário Fiat Mobi 2022*. Fiat Automóveis, Brasil (2022).