E. G. Reis, C. S. M. Furtado, Rev. Bras. Crim. 2026
Edição Especial dos Anais do XXVIII Congresso Nacional de Criminalística

2026
ISSN 2237-9223

REVISTA BRASILEIRA DE CRIMINALÍSTICA

Edição Especial dos Anais do

Estimação de degradação espectral acumulativa em cadeias de codificação com perdas em áudio forense: estudo com 32.292 amostras

E. G. Reis[a,*], C. S. M. Furtado[a].

[a] *Instituto de Criminalística Carlos Éboli, Secretaria de Estado de Polícia Civil, Rio de Janeiro (RJ), Brasil*
[*] *Endereço de e-mail para correspondência: egreis@pcivil.rj.gov.br. Tel.: +55-21-99651-0097.*

Palavras-chave: Áudio forense; Compressão perceptual; AMR/Opus; Degradação espectral; Likelihood Ratio.

1. INTRODUÇÃO

A interceptação telefônica e análise de áudios de aplicativos de mensageria constituem fontes primárias de prova em investigações criminais. Esses áudios raramente chegam aos laboratórios periciais em forma original: sistemas de telefonia (GSM, UMTS, LTE, 5G) e aplicativos (WhatsApp, Telegram) empregam codecs de compressão com perdas — AMR-NB, AMR-WB, Opus — que descartam componentes espectrais consideradas psicoacusticamente irrelevantes [1,2].

A situação agrava-se quando o áudio é submetido a múltiplas transcodificações. Por exemplo, uma ligação VoLTE gravada, convertida para MP3 e reenviada via WhatsApp acumula três compressões com perdas. Cada recompressão introduz novos artefatos e elimina informação espectral adicional, comprometendo progressivamente a qualidade forense do material [3,4].

Apesar da ubiquidade desse fenômeno, a literatura forense carece de estudos quantitativos sistemáticos sobre efeitos cumulativos da recompressão em análises periciais específicas. Estudos anteriores focaram principalmente em detecção de dupla compressão (duas gerações) [3–5], com datasets limitados (<1000 amostras) e restritos a um único codec [6,7]. Este trabalho visa preencher essas lacunas desenvolvendo sistema automatizado de detecção e quantificação de degradação por compressões sucessivas.

1.1. Objetivos

1.1.1. Objetivo geral

Desenvolver e validar sistema automatizado de quantificação de degradação espectral induzida por compressões sucessivas com codecs perceptuais (0 a 4 gerações).

1.1.2 Objetivos específicos

(1) Construir dataset controlado representativo (32.292 amostras) com histórico de compressão conhecido; (2) Identificar features espectrais discriminativas para classificação de gerações; (3) Treinar classificador robusto com métricas forenses apropriadas; (4) Calibrar sistema de Likelihood Ratio seguindo framework Bayesiano [8,9]; (5) Estabelecer sistema de níveis de adequação pericial baseado em evidências empíricas.

2. MATERIAIS E MÉTODOS

2.1. Composição do Dataset

Base: 23 falantes masculinos, brasileiros, Estado do Rio de Janeiro, idade entre 20 e 60 anos. Áudio original capturado em 44,1 kHz, 16 bits, formato PCM sem processamento, no estilo conversação espontânea, com gravações entre 1:30 e 1:45 minutos.

Gen0 (Reamostragem): Criadas 4 versões reamostradas (8, 12, 16, 48 kHz) sem aplicação de codec, simulando diferentes taxas de captura = 92 arquivos.

Gen1 (Primeira compressão): Cada Gen0 codificado com codec apropriado em 35 combinações tecnologia/ambiente simulando: GSM 2G (5 variantes AMR-NB), UMTS 3G (6 variantes), VoLTE 4G (8 variantes AMR-WB), VoNR 5G (7 variantes), 5G interceptado (4 perfis), WhatsApp (5 perfis Opus) = 805 arquivos.

Gen2-4 (Recompressões sucessivas): Cada Gen(n) recomprimido com 3 bitrates diferentes gerando Gen(n+1). Progressão: Gen2=2.415, Gen3=7.245, Gen4=21.735 arquivos.

Dataset controlado: 32.292 arquivos canônicos derivados de 23 falantes masculinos após deduplicação por hash SHA-256.

2.2. Extração de features

Total de 47 features espectrais extraídas via Short--Time Fourier Transform (STFT) com janela Hann de 2048 samples e overlap de 75%. Todos os áudios foram reamostrados para 48 kHz antes da extração, garantindo que as bandas de frequência (Low 0–2 kHz, Mid 2–6 kHz, High 6–10 kHz) sejam comparáveis entre tecnologias de diferentes larguras de banda.

Lacunas espectrais (holes): Fração de bins com magnitude < -60 dB em três bandas: Low (0-2 kHz), Mid (2-6 kHz), High (6-10 kHz). Percentis (p05, p25, p50, p75, p95) e estatísticas (média, desvio).

Alta frequência (HF/Temporal): hf_active_ratio (percentual de frames com energia > -40 dB em 4-8 kHz), hf_flatness (planicidade espectral via razão média geométrica/aritmética), hf_rolloff (frequência abaixo da qual está 85% da energia), severe_hf_fraction (fração de frames com energia HF < -60 dB).

Energia e entropia: Densidade de energia por Hz, razões energia HF/total e LF/total, entropia espectral por banda, sparsity de Hoyer.

2.3. Classificação Random Forest

Algoritmo: Random Forest com 100 estimadores, profundidade máxima 20, mínimo 5 samples por split. Para prevenir data leakage, o split treino-teste foi realizado com disjunção completa por falante (speaker-disjoint split via GroupShuffleSplit). Validação cruzada: StratifiedGroupKFold com 5 folds. Baselines: threshold em hf_active_ratio (78%), árvore de decisão (76%). Random Forest superou melhor baseline em +9 pp. Score ordinal: predição contínua [0,4] indicando nível de degradação.

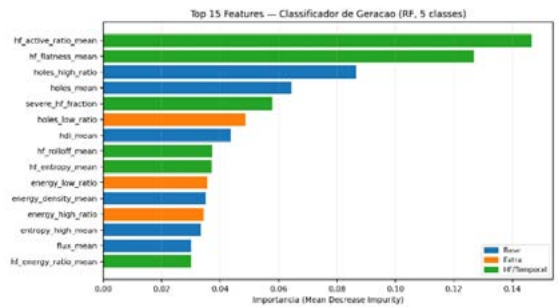


Figura 1. Importância das 15 features mais discriminativas medida por Mean Decrease in Impurity. Features de alta frequência dominam a classificação.

2.4. Sistema de Likelihood Ratio

Para cada geração G, likelihood ratio é definido na Eq. 1:

$$LR_{G(x)} = \frac{P\,(x|Gen = G)}{P(x|Gen \neq G)} \quad (1)$$

onde as probabilidades são estimadas via Kernel Density Estimation (KDE) Gaussiano [8].

Calibração PAV (Pool Adjacent Violators): Algoritmo isotônico aplicado aos LRs brutos para produzir LRs calibrados preservando ordenação [8,9]. Validação leave-one-out para evitar overfitting.

Métricas de qualidade [9,10]: Cllr (log-likelihood--ratio cost) decomposto em Cllr_min (discriminação) + Cllr_cal (calibração); AUC (área sob curva ROC); Brier Score (erro quadrático probabilístico); ECE (Expected Calibration Error). Gráficos Tippett para visualização de distribuições de LR por classe.

2.5. Sistema de Níveis ENFSI

Para cada par de gerações adjacentes (Gi, Gi+1), foram utilizados três métodos de detecção de threshold: (1) KDE: ponto de cruzamento das densidades de kernel; (2) Youden: maximização de sensibilidade + especificidade; (3) Midpoint: ponto médio entre medianas.

Threshold recomendado calculado como média ponderada, como mostra a Eq. 2, priorizando critério de Youden (60%) por sua maior estabilidade empírica, com KDE (40%) atuando como regularizador suavizando fronteiras via densidades empíricas. Análise de sensibilidade com 5 ponderações distintas confirmou estabilidade dos thresholds (variação < 0,05).

$$t_{rec} = \left(\frac{2 \times t_{KDE} + 3 \times t_{Youden}}{5}\right) \quad (2)$$

Mapeamento para 5 níveis: N0 (score < 1,00); N1 (1,00–1,74: uma compressão); N2 (1,74–2,83: duas compressões); N3 (2,83–3,52: três compressões, degradação severa); N4 (≥ 3,52: quatro ou mais compressões).

3. RESULTADOS

3.1. Desempenho do Classificador

Validação cruzada 5-fold speaker-disjoint (StratifiedGroupKFold): Acurácia global de 87,1% (F1-score macro: 87,2%).

Features mais importantes: hf_active_ratio_mean (15,0%), hf_flatness_mean (12,8%), holes_high_ratio (8,9%), holes_mean (6,5%), severe_hf_fraction (5,8%). Dominância de features HF confirma que codecs perceptuais afetam componentes acima de 4 kHz.

Gen0: recall 90,2%, Gen1: 99,6%, Gen4: 94,7%. Confusão concentrada em Gen2↔Gen3 (recall Gen2: 75%, Gen3: 65,5%). Gen0 e Gen1 corretamente ordenados (score Gen0=0,99 < Gen1=1,07).

3.2. Distribuição do Score Ordinal

Score ordinal por geração: Gen0 (mediana: 0,99), Gen1 (1,07), Gen2 (2,50), Gen3 (3,25), Gen4 (3,88). Progressão monotônica de Gen0 a Gen4 confirmada. Maior salto na transição Gen1→Gen2 (+1,43 pontos), indicando que segunda compressão introduz degradação desproporcional.

Nota: testes estatísticos tratam arquivos como observações independentes; a unidade estatística é o falante (n=23). Modelo misto com efeito aleatório de falante planejado para versão estendida.

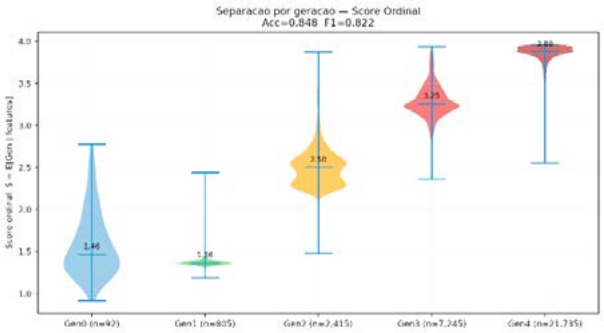


Figura 2. Distribuição do score ordinal por geração. Acurácia: 87,1%; F1: 87,2% (split speaker-disjoint, features a 48 kHz).

3.3. Curvas ROC e Performance Binária

Classificação One-vs-Rest (Figura 3): Gen0 (AUC=1,000), Gen1 (AUC=1,000), Gen2 (AUC=0,906), Gen3 (AUC=0,916), Gen4 (AUC=0,916). Todas as classes com AUC > 0,90 após padronização para 48 kHz.

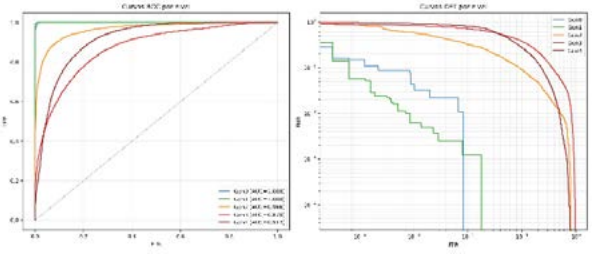


Figura 3. Curvas ROC (esquerda) e DET (Detection Error Tradeoff, direita) para classificação binária One-vs-Rest por geração.

3.4. Calibração e Qualidade do Likelihood Ratio

Métricas Cllr por geração (Figura 4): Gen0 (Cllr=0,610), Gen1 (Cllr=0,176, excelente), Gen2 (Cllr=0,732, aumento de 316% sobre Gen1 — ponto crítico), Gen3 (Cllr=0,819, confiabilidade limitada), Gen4 (Cllr=0,611, melhora pela saturação).

Para Gen2+, Cllr_min domina, indicando que o problema é discriminação, não calibração.

Distribuições Tippett: Gen1 vs demais com boa separação. Gen2+ com proporção crescente na zona inconclusiva.

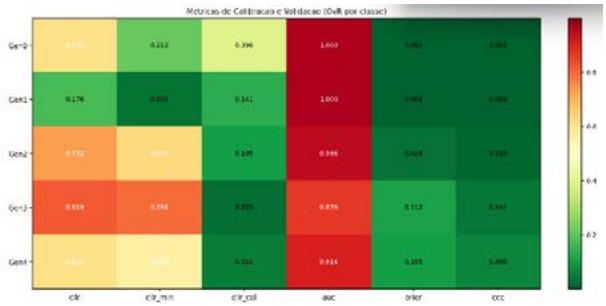


Figura 4. Heatmap de métricas de calibração (Cllr, Cllrmin, Cllrcal, AUC, Brier Score, ECE) por geração. Verde-escuro indica valores desejáveis; vermelho-escuro indica degradação.

3.5. Thresholds ENFSI Calibrados

Thresholds ENFSI calibrados: N0/N1 (Recom.=0,994, AUC=0,593, d=+0,19); N1/N2 (Recom.=1,743, AUC=0,999, d=4,12 — separação excelente); N2/N3 (Recom.=2,833, AUC=0,906, d=2,04); N3/N4 (Recom.=3,521, AUC=0,916, d=1,97).

A AUC moderada na fronteira N0/N1 (0,593) reflete proximidade espectral entre áudio reamostrado e primeira compressão. A separação efetiva inicia-se em N1/N2 (AUC=0,999). Convergência KDE-Youden < 0,05 nas demais fronteiras valida robustez.

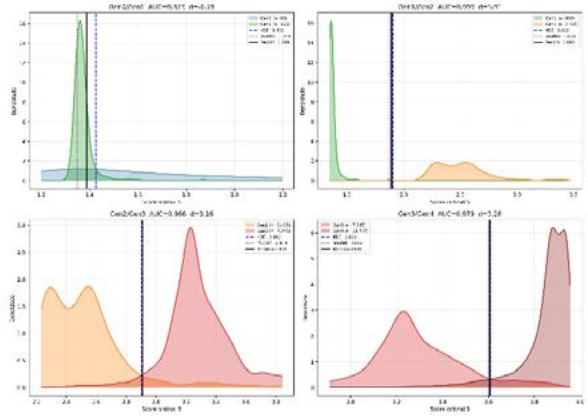


Figura 5. Distribuições de densidade de kernel (KDE) para pares de gera-ções adjacentes com thresholds ENFSI calibrados. Linhas verti-cais: KDE (tracejada), Youden (pontilhada), Recomendado (sólida).

3.6. Independência Tecnológica da Degradação

Convergência dentro do espaço testado em Gen4: gsm_2g, umts_3g, volte_4g, vonr_5g e whatsapp convergem para scores similares (CV < 1%). Extrapolação para codecs fora do espaço testado requer validação.

Dentro do espaço testado, após 4 recompressões todos os áudios convergem para estrutura espectral similar independente do codec de origem [12].

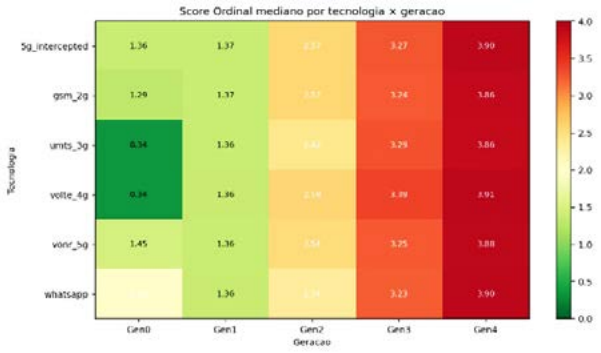


Figura 6. Heatmap do score ordinal mediano por tecnologia × geração. Cores indicam níveis ENFSI calibrados. Convergência universal evidente em Gen4.

4. DISCUSSÃO

4.1. Gen2 como Ponto Crítico Forense

Múltiplas evidências identificam Gen2 como ponto crítico: (1) AUC cai significativamente de N1 para N2; (2) Recall cai de 99,6% para 75%; (3) Score salta +1,43 pontos (Gen1→Gen2).

Verifica-se que a segunda compressão representa transição qualitativa. Gen0→Gen1 envolve degradação controlada por codec calibrado para inteligibilidade. Gen1→Gen2 opera sobre sinal já quantizado, gerando efeitos não-lineares e perda desproporcional de informação [3,4]. Podemos usar a seguinte analogia para a compreensão desse resultado: copiar fotocópia vs copiar original.

4.2. Mecanismos de Degradação Espectral

Perda progressiva de alta frequência: Features HF (hf_active_ratio, hf_flatness) dominam importância discriminativa (24% combinadas). Banda efetiva converge para ~8 kHz após 4 recompressões, mesmo partindo de Opus 48 kHz com banda teórica 20-24 kHz [2]. Codecs alocam bits priorizando inteligibilidade (300-3000 Hz); componentes HF recebem quantização grosseira ou são zeradas [1].

Saturação de features: hf_active_ratio cai progressivamente de Gen0 a Gen4. Gen3 e Gen4 ocupam região similar do espaço de features, explicando o paradoxo de Gen4 ser mais discriminável que Gen3 pela concentração em estado terminal [5].

4.3. Comparação com Estado da Arte

Literatura anterior [3–7] limita-se majoritariamente a: (1) Dupla compressão (2 gerações), não explorando efeitos de 3+ recompressões; (2) Datasets pequenos (<1000 amostras, tipicamente TIMIT com ~500); (3) Mono-codec (apenas AMR-NB, apenas MP3, apenas AAC); (4) Métricas básicas (acurácia, AUC), sem validação via Likelihood Ratio.

Este trabalho avança com: 32.292 amostras (32× maior que típico), exploração de 0-4 gerações, cenário cross-codec (AMR-NB/WB/Opus), sistema ENFSI calibrado com thresholds validados, LR com Cllr completo [8,9], primeira demonstração de saturação de features e independência tecnológica. Korycki (2017) [7] atingiu ~85% para 2 compressões MP3; o sistema desenvolvido neste trabalho alcança 87,1% para 5 classes (0-4 gerações).

4.4. Limitações e Trabalhos Futuros

Limitações: (1) Dataset controlado (23 falantes masculinos, Rio de Janeiro); vozes femininas e outras regiões não representadas. Codecs G.729, Speex, EVS não incluídos. (2) Gen0/Gen1 com AUC moderada (0,593): sistema distingue recompressão mas não diferencia com alta precisão reamostragem de primeira compressão. (3) Testes estatísticos tratam arquivos como independentes (n_efetivo=23 falantes).

Validade de construto: O sistema quantifica degradação espectral acumulada por compressões com perdas. Com reamostragem padronizada para 48 kHz, Gen0 (score 0,99) é corretamente ordenado abaixo de Gen1 (1,07). A separação efetiva inicia-se em N1/N2 (AUC=0,999). Domínio de aplicação: áudios que passaram por codificação com perdas.

Perspectivas futuras: Validação em dataset real, avaliação dos impactos da degradação espectral nos exames e no uso de ferramentas úteis às perícias em áudio (transcrição automática, inferência sobre palavras, verificação de sons, comparação de falantes), expansão de codecs, interface gráfica para peritos não-programadores, integração com detecção de deepfake, análise de interação degradação×SNR, features de segunda ordem (LSTM/Transformers), sistema multimodal (áudio+metadados), proposta de padrão nacional para boas práticas em exames periciais em áudio.

5. CONCLUSÃO

Sistema de classificação de degradação espectral alcançou 87,1% de acurácia (F1=87,2%) em validação cruzada speaker-disjoint com 32.292 amostras de 23 falantes masculinos brasileiros, features extraídas a 48 kHz padronizado.

Achados: (1) Gen2 como ponto crítico (AUC N1/N2=0,999); (2) Features HF dominam (hf_active_ratio 15%); (3) Convergência tecnológica em Gen4

(CV<1%); (4) Progressão monotônica Gen0(0,99)→-Gen4(3,88); (5) Separação efetiva a partir de N1/N2.

Recomendações: Áudios N2+ (score ≥ 1,74) devem ter ressalvas para análises biométricas. Áudios N3+ (score ≥ 2,83) inadequados para identificação de falantes. Sistema complementar à inspeção espectral do perito.

Contribuições: Maior dataset da área, exploração de 0-4 gerações, cenário cross-codec (AMR-NB/WB/Opus), sistema ENFSI calibrado, framework LR para degradação. Trabalhos futuros: expansão de falantes, validação em casos reais, integração com detecção de deepfake.

REFERÊNCIAS BIBLIOGRÁFICAS

[1] J. M. Valin, K. Vos, T. Terriberry. Definition of the Opus Audio Codec. RFC 6716, IETF, 2012.

[2] 3GPP. TS 26.071: AMR speech codec; General description. 3rd Generation Partnership Project, 2020.

[3] D. Luo, R. Yang, J. Huang. Identification of AMR decompressed audio. *Digital Signal Processing* **37**: 85-91 (2015).

[4] D. Luo, W. Luo, R. Yang, J. Huang. Detection of Double Compressed AMR Audio Using Stacked Autoencoder. *IEEE Trans. Information Forensics and Security* **12**: 432-444 (2017).

[5] M. Büker, H. Zeng, H. Zhao. Deep convolutional neural networks for double compressed AMR audio detection. *IET Signal Processing* **15**: 213-225 (2021).

[6] Y. Shen, C. Wang, M. Zhu. Detecting Double Compressed AMR-format Audio Recordings. *Proc. PACCS*: 171-174 (2012).

[7] R. Korycki. Authenticity examination of compressed audio recordings using detection of multiple compression. *Forensic Science International* **270**: 81-91 (2017).

[8] N. Brümmer, J. du Preez. Application-independent evaluation of speaker detection. *Computer Speech & Language* **20**: 230-275 (2006).

[9] G. S. Morrison. Tutorial on logistic-regression calibration and fusion. *Australian Journal of Forensic Sciences* **45**: 173-197 (2013).

[10] D. Meuwly, D. Ramos, R. Haraksim. A guideline for the validation of likelihood ratio methods used for forensic evidence evaluation. *Forensic Science International* **276**: 142-153 (2017).

[11] J. Cohen. *Statistical Power Analysis for the Behavioral Sciences*. 2nd ed. Routledge (1988).

[12] D. Fu, L. Su, G. Cao. A review of double compression detection for digital multimedia. *Neurocomputing* **651** (2025).

[13] V. Hughes, S. Wood, P. Foulkes. Strength of forensic voice comparison evidence from 7000 speakers. *Int. J. Speech, Language and the Law* **26**: 99-132 (2019).