2026
ISSN 2237-9223

REVISTA BRASILEIRA DE CRIMINALÍSTICA

Edição Especial dos Anais do

IDILT: Interface de Desenvolvimento Integrado de Laudo Técnico

D. O. Freitas[a,*], E. S. Martins[b], P. M. Lino[b], F. C. L. Ferreira[a], M. A. Souza[a,c], H. P. Kuribayashi[a,b]

[a]*Programa de Pós-Graduação em Ciências Forenses, Universidade Federal do Sul e Sudeste do Pará, Marabá (PA), Brasil*

[b]*Faculdade de Sistemas de Informação, Universidade Federal do Sul e Sudeste do Pará, Marabá (PA), Brasil*

[c]*Faculdade de Engenharia da Computação, Universidade Federal do Sul e Sudeste do Pará, Marabá (PA), Brasil*

**Endereço de e-mail para correspondência: danfreitas97@unifesspa.edu.br Tel.: +55-61-99271-3489.*

Palavras-chave: Laudo Técnico; Inteligência Artificial; Modelos de Linguagem; Geração Aumentada por Recuperação

1. INTRODUÇÃO

De acordo com dados do 19º Anuário Brasileiro de Segurança Pública, o país registrou 44.127 mortes violentas intencionais em 2024, além de elevados índices de crimes patrimoniais, violência doméstica e desaparecimentos [1, 2]. Cada uma dessas ocorrências demandou procedimentos periciais especializados, envolvendo análise de vestígios, exames laboratoriais e elaboração de laudos técnicos. Neste contexto, a atividade pericial criminal ocupa papel central no sistema da justiça criminal brasileira. Em termos práticos, o laudo pericial é essencial para o inquérito policial, uma vez que a denúncia depende da prova de materialidade e indícios de autoria [3]. Desta forma, no contexto do ordenamento jurídico brasileiro, a atividade pericial encontra respaldo no Código de Processo Penal (CPP), conforme estabelece o Art. 158 do CPP [4].

Desta forma, o laudo assume papel central na persecução penal, uma vez que representa a materialização da prova técnica produzida durante a investigação criminal. A elaboração do laudo inicia-se ainda na preservação do local de infração penal, passando pela coleta, acondicionamento, análise e interpretação dos vestígios, etapas diretamente relacionadas à cadeia de custódia [4]. Paralelamente ao aumento da demanda investigativa, observa-se uma limitação estrutural relacionada à capacidade operacional dos órgãos de perícia oficial no Brasil. O crescimento contínuo do número de ocorrências criminais, associado à diversificação dos vestígios analisados, incluindo evidências digitais, biológicas, químicas e balísticas, amplia significativamente a complexidade das atividades desempenhadas pelos peritos criminais. Entretanto, muitos Institutos de Criminalística enfrentam desafios relacionados à insuficiência de recursos humanos, elevada carga de trabalho, necessidade de respostas em prazos reduzidos e acúmulo de exames periciais pendentes [5].

Nesse contexto, os avanços recentes em Inteligência Artificial (IA), especialmente em modelos de linguagem de grande escala (*Large Language Models* - LLMs), têm aberto novas perspectivas para o desenvolvimento de ferramentas computacionais de apoio à atividade pericial. Essas tecnologias apresentam potencial para auxiliar na organização e estruturação de informações, recuperação semântica de conteúdos técnicos e padronização documental [6]. Por outro lado, a aplicação de IA generativa em ambientes periciais demanda cuidados relacionados à confiabilidade, rastreabilidade das informações, transparência dos processos automatizados e conformidade com os princípios técnico-científicos da prova pericial. Nesse sentido, este trabalho apresenta o IDILT, acrônimo de Interface de Desenvolvimento Integrado de Laudo Técnico, uma plataforma de apoio à elaboração de laudos periciais baseada em LLMs e Geração Aumentada por Recuperação (*Retrieval Augmented Generation* - RAG), concebida para auxiliar a estruturação e a produção assistida de documentos técnico-científicos. A solução adota uma arquitetura

multi-agente, operando sob o paradigma *human-in-the-loop* (HITL), no qual o modelo de IA atua exclusivamente como ferramenta de apoio analítico e documental, mantendo o perito oficial como responsável pela validação técnica, interpretação dos vestígios e aprovação final do laudo pericial.

O restante deste trabalho está organizado da seguinte forma: a Seção 2 apresenta a fundamentação teórica, enquanto a Seção 3 descreve os requisitos do domínio pericial e os requisitos funcionais da plataforma IDILT. A Seção 4 apresenta a arquitetura proposta, incluindo os mecanismos de recuperação semântica e estratégias de validação. A Seção 5 discute as potencialidades e limitações da solução proposta. Por fim, a Seção 6 apresenta as conclusões do trabalho e os direcionamentos para pesquisas futuras.

2. FUNDAMENTAÇÃO TEÓRICA

A literatura relacionada indica que a integração LLMs e RAG viabiliza o uso de IA em domínios de conhecimento intensivo, mitigando a ocorrência de alucinações e provendo o rigor factual e a rastreabilidade documental necessários à elaboração de documentos técnicos [7-9]. Neste contexto, os LLMs consistem em sistemas computacionais projetados para o processamento avançado de linguagem natural, operando com notável eficácia em tarefas de compreensão e geração de textos [10]. Por meio do pré-treinamento em conjuntos de dados massivos, esses modelos extraem padrões estatísticos e estruturas linguísticas, o que lhes permite interpretar nuances semânticas e contextos textuais complexos. Em decorrência do elevado número de parâmetros e da escala de treinamento, a literatura reporta que os LLMs apresentam capacidades emergentes, como tarefas de raciocínio lógico e síntese, sem a necessidade de retreinamento ou ajuste fino (*fine-tuning*) explícito para o domínio alvo [11]. Para suplantar as deficiências paramétricas dos LLMs, a RAG tem se estabelecido como o paradigma metodológico de referência [7-11]. Técnicas de RAG acoplam um módulo de recuperação de informação a um LLM, fundamentando as respostas do modelo em uma memória não-paramétrica. Esta ancoragem em bases documentais externas validadas reduz de forma drástica a ocorrência de alucinações factuais e garante a auditabilidade das fontes empregadas no texto gerado [12]. O processo operacional do RAG estrutura-se em três estágios: indexação, recuperação e geração. Na etapa de indexação, o acervo documental de referência é particionado em fragmentos (*chunks*). Estes fragmentos são processados por modelos de codificação (*embeddings*), que os convertem em representações vetoriais de alta dimensionalidade. Tais vetores são então armazenados em bancos de dados vetoriais, otimizados para buscas semânticas escaláveis [7, 12]. Durante a inferência, a consulta do usuário é igualmente vetorizada. O módulo de recuperação mapeia e extrai os fragmentos indexados que apresentam maior proximidade semântica com a consulta, comumente empregando métricas de distância como a similaridade de cosseno [12]. Em sequência, métodos de re-ranqueamento (*reranking*) baseados em *cross-encoders* são aplicados para refinar os resultados, filtrando fragmentos que possuem sobreposição de palavras, mas são fracamente relacionados sob a óptica lógica [7].

Para o domínio pericial, este fluxo tecnológico assegura que a construção argumentativa do laudo não dependa da "memória" probabilística ou treinamento do algoritmo, mas sim da literatura e das normativas explicitamente injetadas no sistema, conferindo integridade, rastreabilidade e validade científica ao artefato gerado. Embora a arquitetura RAG propicie uma mitigação expressiva de alucinações, a literatura reconhece que falhas de recuperação e de geração constituem desafios inerentes à técnica [13]. Inconsistências na indexação, vieses no acervo documental e limitações semânticas dos algoritmos de busca podem introduzir erros em cascata no fluxo de processamento [14]. Sob essa óptica, para resguardar a validade e a rastreabilidade das análises no domínio pericial, a operação desses sistemas deve submeter-se ao paradigma HILT, onde a IA atua exclusivamente como um instrumento de apoio analítico e cognitivo, configurando-se como um assistente, e não como um decisor autônomo [12]. Assim, a validação do laudo gerado, o escrutínio das evidências recuperadas e a chancela da integridade ética permanecem sob a responsabilidade intransferível do perito. O especialista atua como a salvaguarda indispensável para filtrar sugestões espúrias e assegurar que o documento satisfaça o rigor factual exigido pela práxis investigativa.

3. REQUISITOS FUNCIONAIS DO DOMÍNIO PERICIAL

Quanto aos requisitos da escrita do laudo técnico, cada organização possui suas subáreas onde o laudo deverá atender quesitos antes elaborados, e devem descrever quais os métodos utilizados para realizar o exame pericial. O perito ao ser designado ao caso, deve descrever detalhadamente os vestígios coletados e examinados, com estrita observância aos prazos

legais vigentes [15]. Por outro lado, para o desenvolvimento do IDILT há a necessidade de definição de requisitos funcionais, que relacionam as necessidades previamente acordadas segundo as demandas periciais. Esses requisitos garantem que haja o cumprimento das reais necessidades do usuário do sistema, durante o processo de implementação do sistema [16]. A Tabela 1 apresenta a lista de requisitos funcionais do IDILT. Estes requisitos funcionais foram identificados após um processo formal de elicitação de requisitos com peritos criminais, onde os projetistas da plataforma estabeleceram uma série de perguntas aos peritos, para melhor entendimento do funcionamento do sistema e elaboração das documentações necessárias para o sistema. Esses requisitos não representam a versão final do sistema, podendo ter seu escopo ampliado devido às necessidades dos usuários, e a escalabilidade da solução, porém os requisitos funcionais determinados nessa documentação têm que ser garantidos pelos desenvolvedores no resultado da confecção inicial da solução.

Tabela 1. Requisitos Funcionais do IDILT.

Requisitos Funcionais do IDILT	
Identificador	**Nome do Requisito**
RF01	Autenticação de Usuário
RF02	Controle de Perfis de Acesso
RF03	Gerador de Pré-Laudo
RF04	Editor Estruturado de Pré-Laudo
RF05	Interação com Inteligência Artificial
RF06	Verificação das Informações
RF07	Exportação de Documento

Os requisitos RF01 e RF02 garantem a segurança e a confiabilidade do sistema por meio da autenticação de usuários e do controle de acesso, assegurando que apenas pessoas previamente cadastradas utilizem a plataforma. A solução para o problema apontado pelos peritos criminais é respaldada pelos requisitos RF03 e RF06, que estabelecem a estrutura de confecção de pré-laudos com inteligência artificial integrada. Complementarmente, os requisitos RF04 definem critério da interface; o IDILT busca alinhar-se aos padrões de Interface Humano-Computador (IHC), que são conjuntos de boas práticas de design utilizados para orientar a criação de sistemas digitais mais intuitivos e eficientes, recomendados pela literatura [17]. Por outro lado, o requisito RF06 garante a verificação das informações fornecidas pela IA por meio de um recurso de revisão previamente descrito, assegurando a confiabilidade e a segurança das informações fornecidas ao perito criminal. Por fim, o requisito RF07 permite exportar a documentação que foi gerada pelo IDILT, revisada e editada pelo perito criminal, podendo efetuar o download do Pré-Laudo em formato editável, para que seja possível alterações adicionais a serem feitas pelo próprio perito.

4. PROPOSTA DE SOLUÇÃO

Neste estudo, propomos uma plataforma de RAG estruturada sob um paradigma multi-agente, a ser implantada em infraestrutura estritamente local (*on-premise*). A literatura recente evidencia que sistemas RAG adaptados para domínios específicos superam abordagens genéricas ao ancorar a geração textual exclusivamente em diretrizes técnicas, manuais e normativas institucionais previamente validadas [13]. Consequentemente, para satisfazer as restrições de sigilo e cadeia de custódia inerentes à segurança pública, a solução delineada afasta-se de modelos em nuvem. Em particular, o IDILT emprega LLMs de pesos abertos (*open-weights*) em um ambiente isolado, garantindo a governança e a auditabilidade integral das informações processadas [18, 19]. A espinha dorsal de comunicação e segurança da arquitetura apoia-se no *Model Context Protocol* (MCP). Este protocolo opera como um barramento de integração que padroniza as interações entre o LLM, os agentes cognitivos especializados e os repositórios de dados [18, 20]. O MCP viabiliza o Controle de Acesso Baseado em Funções (RBAC) e a delimitação estrita de permissões, prevenindo a contaminação cruzada de contextos [18]. Em última análise, esta infraestrutura transforma o modelo generativo de um oráculo probabilístico isolado em um assistente analítico orquestrado, cujas ações são rastreáveis e verificáveis [19]. A arquitetura do IDILT estrutura-se em uma topologia multi-agente, orquestrada de forma centralizada pelo MCP, conforme demonstrado na Figura 1. Diferentemente de abordagens generativas monolíticas, o processamento cognitivo é segmentado entre agentes especialistas, o que reduz a sobrecarga do Modelo de LLM e mitiga a ocorrência de alucinações em tarefas complexas [21]. O fluxo de funcionamento operacionaliza-se em quatro estágios inter-relacionados: (1) recepção da consulta do usuário e classificação de intenção; (2) roteamento pelo orquestrador MCP para o agente especialista adequado (ex: Agente de Consulta Normativa ou Agente Analista); (3) recuperação semântica das diretrizes nas bases vetoriais locais; e (4) síntese estruturada e verificação autorreflexiva da resposta antes da exibição ao especialista humano [21].

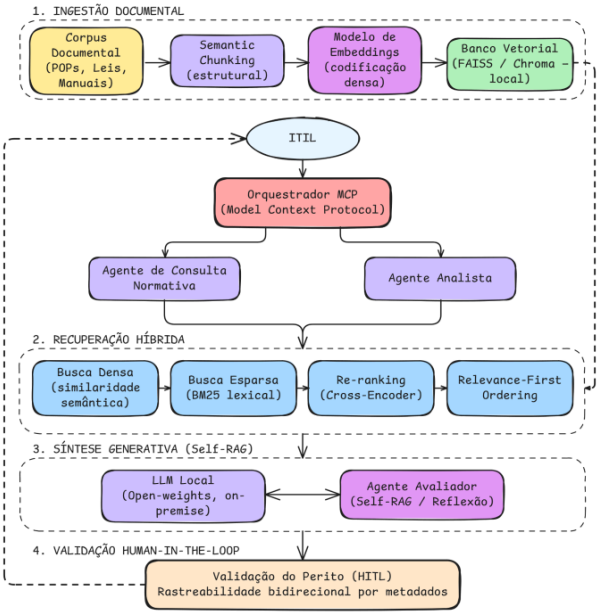


Figura 1. Proposta de Arquitetura Multi-Agente do IDILT.

Assim, o protocolo MCP atua como o barramento de integração que encapsula as ferramentas de busca e padroniza a comunicação interna [20]. Para satisfazer os requisitos de auditoria do domínio pericial, o MCP impõe um RBAC e o isolamento de instâncias [19]. Essa camada de governança assegura que cada agente interaja exclusivamente com os repositórios documentais estritamente necessários à sua operação, prevenindo vetores de ataque, como injeção de prompts interagentes, e garantindo a rastreabilidade das ações [19]. Assim, o fluxo resguarda a soberania da informação, visto que o orquestrador, os bancos de dados e os LLMs de pesos abertos serão executados integralmente em infraestrutura local sem dependência de APIs externas em nuvem [22]. Para fundamentar o raciocínio algorítmico de forma sólida, o pipeline de ingestão processa exclusivamente um *corpus* documental técnico, composto por Procedimentos Operacionais Padrão (POPs), legislações vigentes, manuais operacionais e normas [13]. Consequentemente, o sistema adota uma estratégia de fragmentação estrutural e semântica (*semantic chunking*) [7, 23]. Este método identifica e preserva as fronteiras lógicas dos documentos, como limites de parágrafos, incisos legais e tabelas técnicas, garantindo que as diretrizes normativas e suas dependências não sejam rompidas de forma arbitrária [23]. Após o particionamento, os fragmentos textuais são submetidos a modelos de codificação densa (modelos de *embedding*) otimizados para captura de semântica complexa, sendo convertidos em representações vetoriais de alta dimensionalidade [12, 13]. Esses vetores, intrinsecamente associados aos seus metadados de origem (ex: identificador da norma, data de vigência e número da página), são persistidos em um banco de dados vetorial local.

No estágio de inferência, o sistema processa a consulta do perito empregando uma estratégia de busca híbrida. Esta abordagem metodológica funde a recuperação densa (baseada em similaridade semântica) com a recuperação esparsa (baseada em correspondência lexical, como o algoritmo BM25) [24]. A literatura demonstra que a combinação destes paradigmas garante a localização exata de terminologias técnicas e incisos legais, compensando as perdas de informação inerentes à vetorização isolada e otimizando a recuperação do acervo normativo [24]. Após a recuperação preliminar, os fragmentos documentais candidatos são submetidos a um refinamento estrito de contexto. Modelos de re-ranqueamento baseados em codificadores cruzados (*cross-encoders*) reavaliam a correlação lógica entre a consulta e cada fragmento, filtrando correspondências espúrias e informações fracamente relacionadas [7]. Para mitigar a degradação de desempenho em contextos extensos, vulnerabilidade documentada como "*lost in the middle*" [25], a arquitetura adota a estratégia de Ordenação Prioritária por Relevância (*Relevance-First Ordering*). Neste arranjo, os fragmentos normativos de maior precisão são injetados nas extremidades da janela de contexto do LLM, maximizando a atenção do modelo generativo sobre os fragmentos primordiais [25]. Durante a fase de síntese, a arquitetura implementa o paradigma de RAG Autorreflexiva (*Self-RAG*). O modelo não assume a primeira síntese gerada de forma passiva; pelo contrário, um agente avaliador interno critica iterativamente a própria saída, confrontando as afirmações geradas diretamente com os fragmentos recuperados [26]. Caso o avaliador detecte inconsistências factuais ou insuficiência probatória, o sistema descarta a geração, reformula a consulta e reprocessa a inferência, reduzindo drasticamente a ocorrência de alucinações em tarefas de alta complexidade [26].

5. METODOLOGIA DE USO DA FERRAMENTA

A Figura 3 apresenta um fluxograma com a metodologia de uso do IDILT. A metodologia proposta estrutura-se nos estágios de autenticação, exibição do dashboard principal, análise de casos periciais, incluindo a edição do pré-laudo e sua consolidação. O processo de interação do perito com a plataforma começa na tela de autenticação, garantindo a confidencialidade dos dados e a validação das credenciais do usuário no sistema. Posteriormente, o usuário é

encaminhado para o ambiente principal e responsável por mostrar informações gerais e gráficas relacionadas ao funcionamento da ferramenta, podendo o usuário navegar entre os módulos da plataforma através de um menu lateral. Na tela de Casos, o perito visualiza todos os casos previamente cadastrados sob sua responsabilidade, além de permitir a criação de novos casos, sendo este módulo primordial para o gerenciamento, centralizando todas as informações fundamentais para a confecção de pré-laudos, a partir desse módulo, o usuário pode utilizar a tela de edição. No ambiente de edição, o usuário tem seções predeterminadas pelos padrões de confecção de laudos periciais, pode personalizar e criar suas próprias seções, promovendo maior padronização na confecção dos laudos periciais. Sendo assim, o fluxograma mostra a integração entre as telas do IDILT e a interação do usuário com a plataforma de forma eficaz.

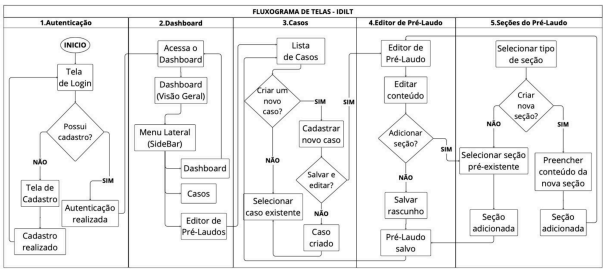


Figura 3. Fluxograma de funcionamento do IDILT.

Por fim, o fluxo de automação encerra-se sob o paradigma HITL. O documento preliminar estruturado pela IA, rigorosamente acompanhado das respectivas citações normativas e rastros de auditoria, é exposto na interface do especialista para escrutínio [12]. A validação final, a interpretação do contexto do crime e a chancela legal do laudo permanecem sob a responsabilidade intransferível do perito humano. Nesse contexto, o sistema atua como um instrumento de síntese normativa e assistência à elaboração de laudos técnicos, resguardando o rigor metodológico e a segurança exigidos na atuação forense. No fluxo final de processamento, as informações sintetizadas pelos agentes são apresentadas ao perito para revisão. Para assegurar a auditabilidade do processo, cada segmento de texto gerado é obrigatoriamente acompanhado de vínculos de metadados rastreáveis, os quais remetem o usuário de forma direta aos documentos normativos e diretrizes originais recuperados pelo sistema. Esta rastreabilidade bidirecional viabiliza o escrutínio imediato das fontes, permitindo que o especialista analise, refine ou descarte as sugestões formuladas pelo modelo antes da consolidação do documento [12].

Conforme apresentado na Figura 4, para melhor satisfação do usuário no uso da ferramenta, no processo de prototipação de um sistema a interface utiliza diversas diretrizes de usabilidade. A visibilidade do status do sistema é evidenciada pela exibição do horário do último salvamento automático e das métricas em tempo real do documento, como número de palavras, caracteres e seções, mantendo o usuário continuamente informado da edição e confecção do documento. O painel lateral direito aplica a diretriz de prevenção de erros, sinalizando antecipadamente campos ausentes e inconsistências terminológicas antes do envio do relatório, sendo este, onde fica localizado o agente de IA integrado, em que o usuário pode visualizar as sugestões e também pode utilizar o chat interativo com a ferramenta. As sugestões são classificadas por prioridade com diferenciação por cor e ícone. Por fim, o controle do usuário é garantido pela possibilidade de dispensar sugestões individualmente e acionar a reanálise manualmente, de modo que nenhuma alteração seja aplicada sem consentimento do usuário [17].

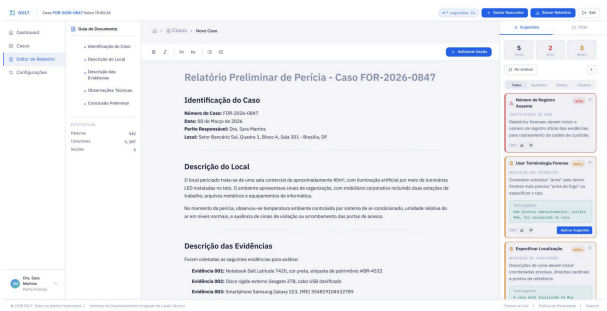


Figura 4. Interface do módulo Editor de Pré-Laudo do IDILT.

Não obstante os benefícios delineados, a adoção de sistemas baseados em LLMs e RAG não é isenta de desafios materiais e operacionais documentados. A precisão da síntese gerativa permanece intrinsecamente dependente da eficácia do módulo de recuperação e falhas na indexação ou a recuperação de fragmentos ambíguos propagam erros contextuais em cascata, degradando a qualidade técnica do laudo [13]. Outrossim, a exigência de implantação local (*on-premise*) para garantir a soberania dos dados sensíveis impõe severas restrições de infraestrutura. Esta barreira computacional pode dificultar a escalabilidade do sistema em corporações de segurança pública que operam sob rigorosas restrições orçamentárias. Por fim, do ponto de vista do comportamento organizacional, há o risco sistêmico de complacência algorítmica ou excesso de confiança (*over-reliance*) na ferramenta, o que reforça a necessidade de protocolos de supervisão para assegurar que a automação não substitua o escrutínio crítico do perito.

5. CONCLUSÃO E TRABALHOS FUTUROS

A crescente complexidade das demandas periciais e a necessidade de celeridade na produção de documentos técnico-científicos evidenciam a importância de soluções computacionais de apoio à atividade forense. Nesse contexto, o IDILT propõe a integração de Inteligência Artificial, modelos de linguagem e RAG em uma arquitetura multi-agente segura e auditável, concebida para auxiliar a elaboração de laudos técnicos sob o paradigma *human-in-the-loop*. A solução destaca-se pela utilização de infraestrutura local (*on-premise*), mecanismos de recuperação semântica híbrida, validação autorreflexiva e rastreabilidade documental, características que contribuem para a redução de inconsistências, aumento da padronização, fortalecimento da governança da informação e incremento da eficiência operacional dos órgãos periciais, preservando simultaneamente a soberania dos dados e a responsabilidade técnico-científica do perito oficial. Por fim, no âmbito algorítmico, a evolução desta arquitetura requer avanços no campo da Inteligência Artificial Explicável. É imperativo o desenvolvimento de métricas de atribuição que permitam ao operador humano quantificar a influência exata que cada fragmento normativo recuperado exerceu sobre o texto gerado. Adicionalmente, tendo em vista que a literatura técnica e os POPs dependem fortemente de esquemas visuais, tabelas e diagramas, o desenvolvimento de pipelines de RAG multimodal estabelecer-se-á como a próxima fronteira de pesquisa para ampliar a capacidade de compreensão de documentos complexos.

AGRADECIMENTOS

O presente trabalho foi realizado com apoio da Polícia Científica do Estado do Pará e da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior – Brasil (CAPES) – Código de Financiamento 001.

REFERÊNCIAS BIBLIOGRÁFICAS

[1] SILVA, T. H. C. A perícia e o perito criminal contábil: instrumentos a serviço da justiça. Revista Brasileira de Criminalística, v. 8, n. 1, p. 35–47, 2019.

[2] FÓRUM BRASILEIRO DE SEGURANÇA PÚBLICA. 19º Anuário Brasileiro de Segurança Pública 2025. São Paulo: Fórum Brasileiro de Segurança Pública, 2025.

[3] RODRIGUES, C. V., et al. Perícia criminal: uma abordagem de serviços. Gestão & Produção, São Carlos, v. 17, n. 4, p. 843–857, 2010.

[4] BRASIL. Decreto-Lei nº 3.689, de 3 de outubro de 1941. Código de Processo Penal. Diário Oficial da União: seção 1, Rio de Janeiro, RJ, 13 out. 1941. Art. 158.

[5] BRASIL. Ministério da Justiça. Secretaria Nacional de Segurança Pública. Diagnóstico da Perícia Criminal no Brasil. Brasília, DF: SENASP, 2013.

[6] L. Limonad, et al. "Selecting the Right Llm for Egov Explanations," 2025 Eleventh International Conference on eDemocracy & eGovernment (ICEDEG), Bern, Switzerland, 2025, pp. 214-221.

[7] Y. Pu et al., "Customized Retrieval Augmented Generation and Benchmarking for EDA Tool Documentation QA," in IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, vol. 44, no. 12, pp. 4615-4628, Dec. 2025.

[8] M. Zakir Khan, Y. Ge, M. Mollel, J. Mccann, Q. H. Abbasi and M. Imran, "RFSensingGPT: A Multi-Modal RAG-Enhanced Framework for Integrated Sensing and Communications Intelligence in 6G Networks," in IEEE Transactions on Cognitive Communications and Networking, vol. 12, pp. 298-311, 2026.

[9] A. Lecu, A. Groza and L. Hawizy, "Reducing Hallucinations in Medical AI: A Knowledge Graph-Augmented Retrieval System for Evidence-Based Age-Related Macular Evaluation Information," in IEEE Access, vol. 13, pp. 210624-210639, 2025.

[10] H. Elkiran and J. Rasheed, "An Empirical Evaluation of Retrieval, Reranking, and Similarity for a Q&A-Based Retrieval Augmented Generation System," in IEEE Access, vol. 14, pp. 26053-26066, 2026.

[11] J. C. Yelmo, Y. -S. Martín and S. Perez-Acuna, "Experimental Evaluation of AI-Augmented Cybersecurity Requirements Generation Leveraging LLMs' Capabilities," in IEEE Access, vol. 14, pp. 19579-19606, 2026.

[12] R. E. Mallouhy, H. Alqahtani and S. Lardhi, "AI-Powered Standard Operating Procedure Generation and Optimization Using Large Language Models for Chemical Laboratory Applications," in IEEE Access, vol. 14, pp. 19383-19395, 2026.

[13] V. Krainovskikh and T. Samigulin, "Domain-Adapted Retrieval-Augmented Generation for Technical Documentation: Enhancing Reliability and Faithfulness in Technical QA," in IEEE Access, vol. 14, pp. 36016-36024, 2026.

[14] M. Hindi, L. Mohammed, O. Maaz and A. Alwarafy, "Enhancing the Precision and Interpretability of Retrieval-Augmented Generation (RAG) in Legal Technology: A Survey," in IEEE Access, vol. 13, pp. 46171-46189, 2025.

[15] BRASIL. Decreto-Lei nº 3.689, de 3 de outubro de 1941. Código de Processo Penal. Arts. 158-A, 159

e 160, com alterações promovidas pelas Leis nº 13.964/2019, nº 11.690/2008 e nº 8.862/1994.

[16] BITTNER, Kurt; et al. Use Case Modeling. Boston: Addison-Wesley, 2002.

[17] NIELSEN, J. Usability Engineering. San Francisco: Morgan Kaufmann, 1994.

[18] Narayan, O. et. al., “A Comprehensive Security Framework for the Model Context Protocol (MCP) in Multi-Agent AI Systems”, 2025.

[19] T. P. Patel, et al., "Model Context Protocol Business Analyst (MCP-BA): A Governed and Explainable Framework for Enterprise Analytics: Operationalizing Identity-Aware Reasoning and Context-Driven Decision Intelligence in Enterprise AI," 2025 International Conference on Computer and Applications (ICCA), Bahrain, Bahrain, 2025, pp. 1-7.

[20] N. Nargund, et al, "Model Context Protocol (MCP): A Lightweight, Modular Framework for Tool-Augmented LLM Agents," 2025 13th International Conference on Intelligent Systems and Embedded Design (ISED), Raipur, India, 2025, pp. 175-180.

[21] V. Yadav, Gaurav, A. Rana and S. Sharma, "MedRAG-Agent: Medical Query Resolution By Employing A Multi-Agent, Knowledge Graph-Enhanced RAG-Based AI Framework," 2025 IEEE 6th Global Conference for Advancement in Technology (GCAT), Bangalore, India, 2025, pp. 1-4.

[22] S. Sriram, C. H. Karthikeya, K. P. Kishore Kumar, N. Vijayaraj and T. Murugan, "Leveraging Local LLMs for Secure In-System Task Automation With Prompt-Based Agent Classification," in IEEE Access, vol. 12, pp. 177038-177049, 2024.

[23] A. Agrawal, P. Acharya, M. M. M. Pai and R. M. Pai, "Algorithmic Document Processing and Retrieval-Augmented Generation for Industrial Knowledge Transfer: A Comprehensive Framework for Technical Manual Processing," 2025 2nd Asia Pacific Conference on Innovation in Technology (APCIT), MYSORE, India, 2025, pp. 1-5.

[24] H. Altınok, H. Tekgoz, H. Erdoğan and H. Uz, "A Comparative Analysis of Retrieval-Augmented Generation Architectures with Semantic Hashing for Enterprise Knowledge Systems," 2026 5th International Informatics and Software Engineering Conference (IISEC), Ankara, Turkiye, 2026, pp. 343-347.

[25] Y. Chen, Z. Huang and Y. Zhang, "Efficient-RAG: Competitive Single-Pass Performance in RAG via Strategic Context Reordering," 2025 18th International Conference on Advanced Computer Theory and Engineering (ICACTE), Nanjing, China, 2025, pp. 188-194.

[26] R. More, "A Unified Evaluation Framework for Grounded LLM Architectures: Comparative Analysis of RAG, Self-RAG, and Agentic RAG," 2025 5th Int. Conf. on Artificial Intelligence and Signal Processing (AISP), Vijayawada, India, 2025, pp. 1-5.